Watt's demain : Algorithme de prédiction des données de consommation électrique française

Melissa Aliouche, Nada Haddad, Lola Cusin
M2 Machine Learning for artifical Intelligence (MALIA)

11/11/2026

Cours : Temporal Data Analysis
Enseignant : Jairo Cugliari

Table des matières

1 Introduction **1**

2 Méthodes **1**

2.1 Données et préparation 1
2.2 Analyse exploratoire et protocole temporel 2
2.3 Modèles de référence 3
2.4 Modèles statistiques 4
2.5 Modèles de machine learning 4
2.6 Critères d'évaluation 5

3 Résultats **6**

3.1 Données et analyse exploratoire 6
3.2 Comparaison des prévisions 7
3.3 Contribution des groupes de variables 8
3.4 Performances selon la saison et le type de journée 9
3.5 Erreurs selon la température observée 9
3.6 Autocorrélation des erreurs de prévision 10
3.7 Analyse de trois journées difficiles 12

4 Discussion **13**

4.1 Disponibilité des données et risques de fuite 13
4.2 Analyse de trois journées d'échec 13
4.3 Robustesse et limites des modèles 13
4.4 Trois exemples documentés d'usage des agents IA 13

Références **14**

1 Introduction

Afin d'assurer le bon fonctionnement du réseau électrique, il est nécessaire d'avoir un équilibre entre la production et la consommation d'électricité. La consommation d'électricité est influencée par de nombreux facteurs, tels que la météo, les habitudes de consommation des ménages et des entreprises, et les événements spéciaux. La prévision de la consommation d'électricité est donc un enjeu crucial pour les gestionnaires de réseau : elle permet d'anticiper les besoins, de planifier la production et donc de de garantir la stabilité du système électrique.

Afin de suivre la consommation électrique en temps réel, le Réseau de Transport d'Électricité RTE collecte les données de consommation à l'aide de télémesures transmises directement depuis ses installations (RTE, 2026). Certains de ses sites ne sont pas équipé pour la télémesures, les données sont donc complétées par des estimations, remplacées par la suite par des données de comptage plus complètes. RTE propose également des prévisions de consommation à court terme, qui sont utilisées pour planifier la production et la distribution d'électricité. Ces prévisions sont basées sur des modèles statistiques et des algorithmes d'apprentissage automatique, qui prennent en compte les données historiques de consommation, les conditions météorologiques et d'autres facteurs pertinents.

L'objectif de ce rapport est de proposer un algorithme de prédiction de la consommation électrique française à court terme, en utilisant les données de consommation collectées par RTE. Nous allons explorer différentes approches de modélisation, en utilisant des techniques d'apprentissage automatique et d'analyse de séries temporelles, afin d'obtenir des prévisions précises et fiables. Nous allons également évaluer les performances de notre algorithme en le comparant aux prévisions existantes de RTE, et en analysant les erreurs de prévision pour identifier les points faibles et les opportunités d'amélioration. Nos prédictions s'appuieront sur les données historiques compilées par RTE, ainsi que sur les données météorologiques du réseau SYNOP (Météo-France, 2026), et le calendrier des jours fériés et vacances scolaires en France.

2 Méthodes

2.1 Données et préparation

L'objectif est de prévoir, à 14 h le jour J, les 24 puissances moyennes horaires de consommation électrique du jour $J+1$ en France métropolitaine. La consommation est exprimée en mégawatts (MW). Les données utilisées sont issues d'éCO2mix pour la consommation, du réseau SYNOP pour la météo et des calendriers de jours fériés et de vacances scolaires (Augusti, 2026 ; Gouvernement français, 2026 ; Météo-France, 2026 ; RTE, 2026).

Les stations météorologiques métropolitaines sont retenues si leur couverture sur 2012–2023 est strictement supérieure à 95 % pour la température et pour les précipitations. Les valeurs contradictoires pour une même station et un même instant sont considérées comme manquantes. Les moyennes na-

TABLEAU 1 – Données utilisées et préparation horaire.

Données	Pas initial	Préparation
Consommation	30 minutes	Moyenne des mesures à :00 et :30, datée en début d'heure.
Météo SYNOP	3 heures	Température interpolée et cumul de pluie réparti sur les trois heures précédentes.
Calendrier	1 jour	Jour de semaine, week-end, jours fériés et vacances scolaires.

tionales sont calculées avec des poids égaux entre les stations disponibles. L'écart-type entre stations décrit leur dispersion spatiale et ne constitue pas un intervalle de confiance national.

La consommation et le calendrier sont exprimés en heure civile française. Les dates sont converties en UTC pour effectuer la jointure avec les observations météorologiques. La pluie associée à une heure h correspond à l'intervalle $[h, h+1]$.

Les fichiers RTE conservent 24 étiquettes horaires lors des changements d'heure. Afin d'éviter une ambiguïté sur les instants représentés, les consommations et les données météorologiques de ces journées sont masquées pour la prévision. Les lignes sont toutefois conservées afin de maintenir une grille régulière et des retards correctement espacés.

2.2 Analyse exploratoire et protocole temporel

L'analyse exploratoire porte sur la période d'apprentissage 2012–2023. Elle comprend la représentation de la série, des profils journaliers et hebdomadaires, ainsi que le calcul de moyennes mobiles et de fonctions d'autocorrélation et d'autocorrélation partielle (ACF et PACF).

Pour étudier la saisonnalité hebdomadaire de la série horaire, nous utilisons notamment la différence :

$$Y_t = C_t - C_{t-168},$$

où C_t est la consommation à l'heure t et C_{t-168} celle observée à la même heure sept jours auparavant.

Les données sont séparées chronologiquement en trois périodes :

— apprentissage : 2012–2023 ;
— validation : 2024 ;
— test final réservé : 2025.

Pour chaque journée à prévoir, les modèles utilisent la consommation disponible jusqu'à 8 h le jour J. Cette coupure est une hypothèse conservatrice : la disponibilité historique exacte de toutes les

données RTE à 14 h n'a pas été vérifiée.

La température et les précipitations horaires sont reconstruites à partir d'observations SYNOP espacées de trois heures. Une température interpolée peut dépendre de la mesure suivante ; une pluie horaire provient du cumul de trois heures terminé à la mesure suivante. Nous conservons seulement la météo passée dont cette mesure suivante serait disponible à 14 h le jour J, en supposant un délai de publication de trois heures non vérifié historiquement. La météo effectivement observée pendant $J + 1$ n'est pas utilisée comme variable explicative.

Les méthodes sont évaluées sur les mêmes journées complètes. Une journée est exclue si la cible, les observations historiques nécessaires ou les références des benchmarks sont indisponibles. Cela conduit notamment à exclure les journées de changement d'heure et certaines journées suivantes.

Pour la première prévision de 2024, les modèles de machine learning sont entraînés sur les cibles disponibles jusqu'au 30 décembre 2023. Les modèles statistiques utilisent les observations disponibles jusqu'au 31 décembre 2023 à 8 h. Leurs paramètres restent ensuite fixes pendant la validation, tandis que leurs états sont actualisés avec les observations disponibles avant chaque prévision.

Après la sélection des méthodes sur 2024, le test 2025 prévoit un réentraînement des modèles avec les données de 2012–2024 disponibles avant la première origine de prévision de 2025, sans modifier les configurations retenues. Les états des modèles statistiques seront ensuite actualisés jusqu'à chaque coupure à 8 h, sans réestimer leurs paramètres pendant l'évaluation.

2.3 Modèles de référence

Trois benchmarks sont utilisés : la persistance, la consommation de la semaine précédente et la moyenne des quatre semaines précédentes. Pour une heure cible t et la dernière heure connue c, leurs prévisions sont :

$$\widehat{C}_t^{\text{persistance}} = C_c,$$

$$\widehat{C}_t^{\text{semaine}} = C_{t-168},$$

$$\widehat{C}_t^{\text{4semaines}} = \frac{1}{4}\sum_{k=1}^{4} C_{t-168k}.$$

Les deux références hebdomadaires utilisent ainsi la même heure et le même jour de semaine que la cible. Pour la moyenne sur quatre semaines, les quatre références doivent être disponibles.

2.4 Modèles statistiques

Nous comparons trois modèles de séries temporelles : AR(1), AR(2) et ARMA(1,1). Ils sont ajustés sur la différence hebdomadaire $Y_t = C_t - C_{t-168}$.

Le modèle AR(1) s'écrit :

$$Y_t = \phi_1 Y_{t-1} + \varepsilon_t.$$

Le modèle AR(2) ajoute un second retard :

$$Y_t = \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \varepsilon_t.$$

Le modèle ARMA(1,1) combine un terme autorégressif et un terme de moyenne mobile :

$$Y_t = \phi_1 Y_{t-1} + \varepsilon_t + \theta_1 \varepsilon_{t-1}.$$

Les paramètres sont estimés par maximum de vraisemblance, sans constante. Après prévision de la différence, la consommation est reconstruite à partir de la valeur de la semaine précédente :

$$\widehat{C}_t = C_{t-168} + \widehat{Y}_t.$$

Les critères d'information AIC et BIC complètent la comparaison des modèles statistiques :

$$\mathrm{AIC} = -2\ell(\widehat{\theta}) + 2k, \qquad \mathrm{BIC} = -2\ell(\widehat{\theta}) + k\log(n),$$

où $\ell(\widehat{\theta})$ est la log-vraisemblance évaluée aux paramètres estimés, k le nombre de paramètres et n le nombre d'observations retenu par le logiciel. Une valeur plus faible est préférée pour comparer des modèles ajustés sur la même série. Ces critères ne remplacent pas l'évaluation des prévisions hors échantillon.

2.5 Modèles de machine learning

Quatre modèles sont comparés : une régression linéaire multiple, une régression Ridge, une forêt aléatoire et un gradient boosting.

Les variables explicatives comprennent :

— l'heure et les variables calendaires de la journée à prévoir ;
— les consommations observées entre 0 h et 8 h le jour J ;
— des statistiques et valeurs horaires de consommation et de météo des jours $J-1$, $J-7$, $J-14$ et $J-28$.

La régression linéaire multiple prend la forme :

$$\widehat{C}_t = \beta_0 + \sum_{j=1}^{p} \beta_j X_{t,j}.$$

La régression Ridge ajoute une pénalisation des coefficients au critère des moindres carrés :

$$\sum_t \left(C_t - \widehat{C}_t\right)^2 + \alpha \sum_{j=1}^{p} \beta_j^2,$$

avec $\alpha = 100$ dans notre étude.

La forêt aléatoire combine 100 arbres de profondeur maximale 15. Le gradient boosting utilise 80 arbres de profondeur maximale 2 et un taux d'apprentissage de 0,08. Ces paramètres sont fixés dans les scripts ; leur optimalité n'a pas été démontrée.

Les valeurs manquantes des variables explicatives sont imputées par la médiane calculée sur l'apprentissage. Pour les régressions linéaire et Ridge, les variables sont ensuite standardisées à partir des paramètres estimés sur cette même période.

2.6 Critères d'évaluation

Pour N heures évaluées, nous calculons l'erreur $e_t = C_t - \widehat{C}_t$, puis :

$$\mathrm{MAE} = \frac{1}{N} \sum_{t=1}^{N} |e_t|,$$

$$\mathrm{RMSE} = \sqrt{\frac{1}{N} \sum_{t=1}^{N} e_t^2},$$

$$\mathrm{biais} = \frac{1}{N} \sum_{t=1}^{N} e_t.$$

La RMSE pénalise davantage les erreurs importantes. Un biais négatif indique une surestimation

moyenne.

Nous comparons également l'énergie quotidienne, obtenue en multipliant chaque puissance horaire moyenne par une heure et en additionnant les 24 valeurs. Nous évaluons aussi l'erreur sur la valeur de la pointe et sur son heure, puis les performances par saison, heure et type de journée.

Enfin, les trois journées présentant les plus fortes RMSE quotidiennes du meilleur modèle hors benchmarks sont examinées. Pour l'heure de pointe, la première occurrence du maximum est retenue en cas d'égalité.

3 Résultats

3.1 Données et analyse exploratoire

La sélection météorologique retient 37 stations SYNOP métropolitaines. Selon la grille géographique la plus fine, 45,1 % de la surface métropolitaine se trouve à moins de 50 km d'une station et 97,3 % à moins de 100 km. La distance médiane est de 53,0 km.

Cette mesure décrit la proximité géographique mais ne garantit pas que les stations représentent toutes les conditions climatiques ou la répartition de la population.

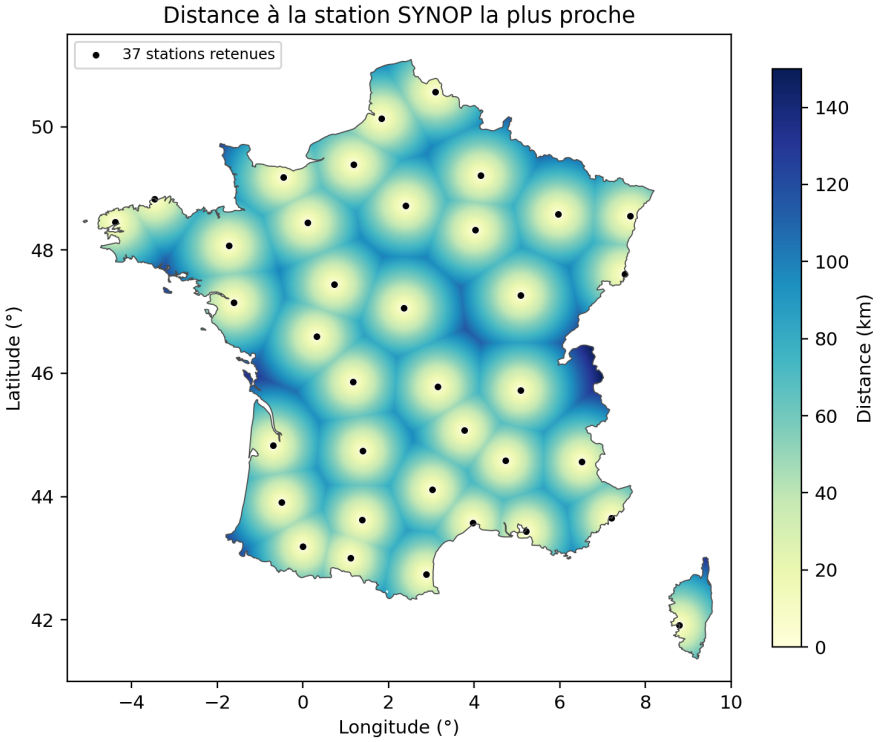
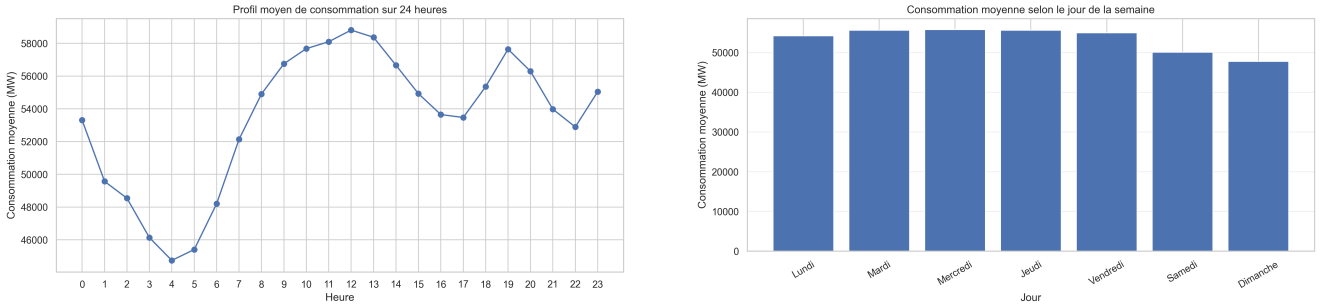


FIGURE 1 – Distance à la station SYNOP retenue la plus proche.

L'exploration de la consommation sur 2012–2023 met en évidence des profils journaliers et hebdomadaires, ainsi qu'une variation saisonnière. La consommation varie selon l'heure et le jour de la semaine, ce qui justifie l'utilisation de variables calendaires et de références hebdomadaires.



(a) Profil journalier moyen.

(b) Profil hebdomadaire moyen.

FIGURE 2 – Profils moyens de consommation sur la période 2012–2023.

La différence à 168 h compare chaque heure à la même heure de la semaine précédente. Elle réduit certains motifs hebdomadaires, mais ne garantit pas à elle seule que la série obtenue soit stationnaire.

3.2 Comparaison des prévisions

Les dix méthodes sont comparées sur 338 journées communes de validation en 2024, soit 8 112 heures par méthode. Les 28 journées restantes sont exclues en raison des changements d'heure, de leurs conséquences sur les historiques nécessaires et des autres critères de disponibilité des observations.

TABLEAU 2 – Erreurs de prévision sur les mêmes heures de validation 2024, en MW.

Modèle	MAE	RMSE	Biais
Forêt aléatoire	1 644	2 383	−146
Régression linéaire	2 015	2 686	−390
Ridge	2 041	2 733	−297
Gradient boosting	2 324	3 093	−647
ARMA(1,1)	2 147	3 291	89
AR(2)	2 177	3 298	114
AR(1)	2 230	3 408	80
Semaine précédente	3 214	4 888	257
Moyenne de quatre semaines	3 705	5 413	291
Persistance	5 659	7 056	−778

La forêt aléatoire obtient les plus faibles MAE et RMSE sur la validation 2024, suivie de la régression linéaire. Par rapport au benchmark de la semaine précédente, elle réduit la MAE de 48,8 % et la RMSE de 51,2 %.

La régression linéaire et la régression Ridge obtiennent des performances relativement proches,

avec des RMSE respectives de 2 686 et 2 733 MW. Elles surpassent notamment le gradient boosting, dont la RMSE atteint 3 093 MW. La complexité d'un modèle ne garantit donc pas une meilleure précision prédictive. Ce classement doit néanmoins être interprété dans le contexte des hyperparamètres retenus, dont l'optimalité n'a pas été démontrée.

Parmi les modèles statistiques, ARMA(1,1) obtient la plus faible RMSE de prévision. Le modèle AR(2) présente toutefois les AIC et BIC les plus faibles. Les critères d'ajustement et les erreurs de prévision hors échantillon ne conduisent donc pas nécessairement au même classement.

La forêt aléatoire présente une erreur absolue moyenne d'énergie quotidienne de 33 478 MWh et une erreur absolue moyenne sur la valeur de la pointe de 1 818 MW. La régression linéaire obtient des erreurs légèrement plus faibles pour ces deux critères : respectivement 33 342 MWh et 1 633 MW.

Pour le benchmark de persistance, l'erreur sur l'heure de pointe est peu interprétable : la prévision est constante sur les 24 heures et la première heure est retenue automatiquement comme heure de pointe.

3.3 Contribution des groupes de variables

Une expérience d'ablation a été réalisée afin d'évaluer la contribution des différentes familles de variables explicatives aux performances de la forêt aléatoire. Trois configurations sont comparées : les variables calendaires seules, leur association avec l'historique de consommation, puis l'ajout des variables météorologiques historiques.

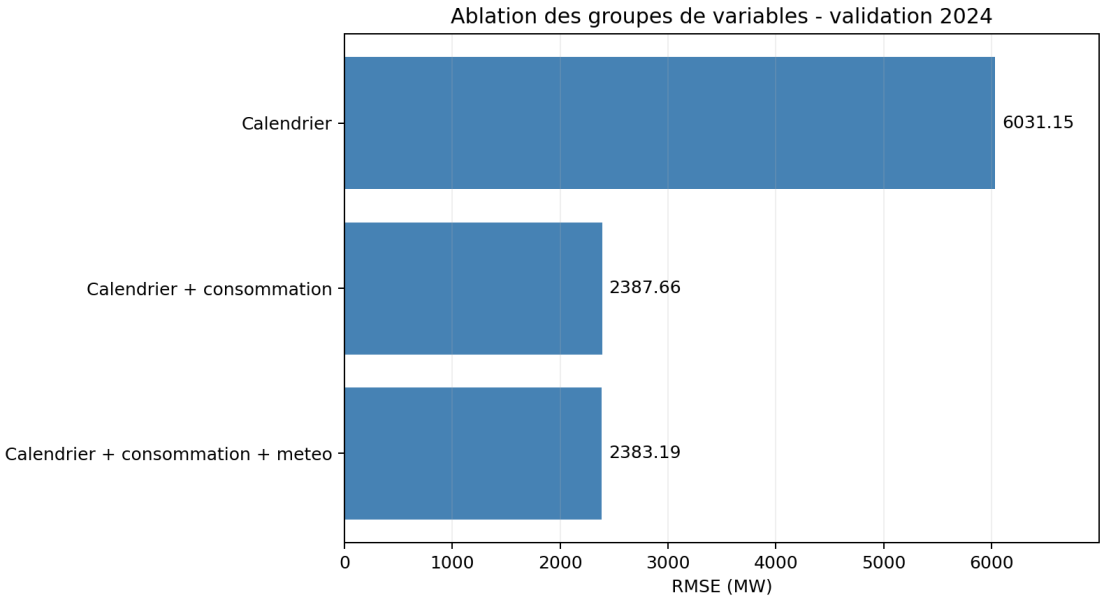


FIGURE 3 – Comparaison des RMSE de validation 2024 pour trois configurations de variables explicatives de la forêt aléatoire.

Avec les seules variables calendaires, la RMSE atteint 6 031,15 MW. L'ajout de l'historique de

consommation la réduit à 2 387,66 MW, soit une diminution relative de 60,4 %. Les observations passées de consommation constituent ainsi une source majeure d'information prédictive pour cette tâche.

L'ajout supplémentaire des variables météorologiques historiques réduit la RMSE à 2 383,19 MW. Ce gain de 4,47 MW représente une amélioration relative d'environ 0,19 % par rapport à la configuration comprenant déjà le calendrier et l'historique de consommation.

Cette faible amélioration suggère que les variables météorologiques historiques apportent peu d'information prédictive supplémentaire dans la configuration étudiée. Elle ne signifie toutefois pas que les conditions météorologiques sont sans influence sur la consommation électrique. Une partie de leur effet peut notamment être déjà reflétée dans l'historique de consommation.

L'expérience ne permet pas, à elle seule, de déterminer si ce faible gain est statistiquement significatif ou s'il se généralise à d'autres périodes et configurations.

3.4 Performances selon la saison et le type de journée

Les performances de la forêt aléatoire varient selon la saison. Sa RMSE est de 1 065 MW en été, contre 3 546 MW en hiver. Cette différence pourrait notamment être liée aux variations saisonnières de la consommation et à sa sensibilité aux conditions météorologiques. Ces facteurs ne peuvent toutefois pas être isolés à partir de cette seule comparaison.

La RMSE atteint 3 175 MW pour les jours fériés, contre 2 361 MW pour les autres journées. Cette comparaison repose toutefois sur seulement huit journées fériées évaluées ; elle doit donc être interprétée avec prudence.

3.5 Erreurs selon la température observée

Afin d'examiner les performances des modèles dans différentes conditions thermiques, les erreurs horaires de la forêt aléatoire et du benchmark de la semaine précédente sont regroupées selon la température observée.

Cette analyse est réalisée a posteriori : les températures observées servent uniquement à caractériser les conditions associées aux erreurs. Elles ne correspondent pas à des températures futures connues au moment de la prévision.

La forêt aléatoire présente une RMSE inférieure à celle du benchmark de la semaine précédente dans chacune des trois catégories disposant d'une température observée.

Les erreurs augmentent lorsque les températures diminuent, particulièrement pour le benchmark hebdomadaire. Aux températures inférieures à 5 °C, celui-ci présente une dégradation plus marquée que la forêt aléatoire.

Ces différences sont compatibles avec une difficulté accrue à prévoir la consommation dans cer-

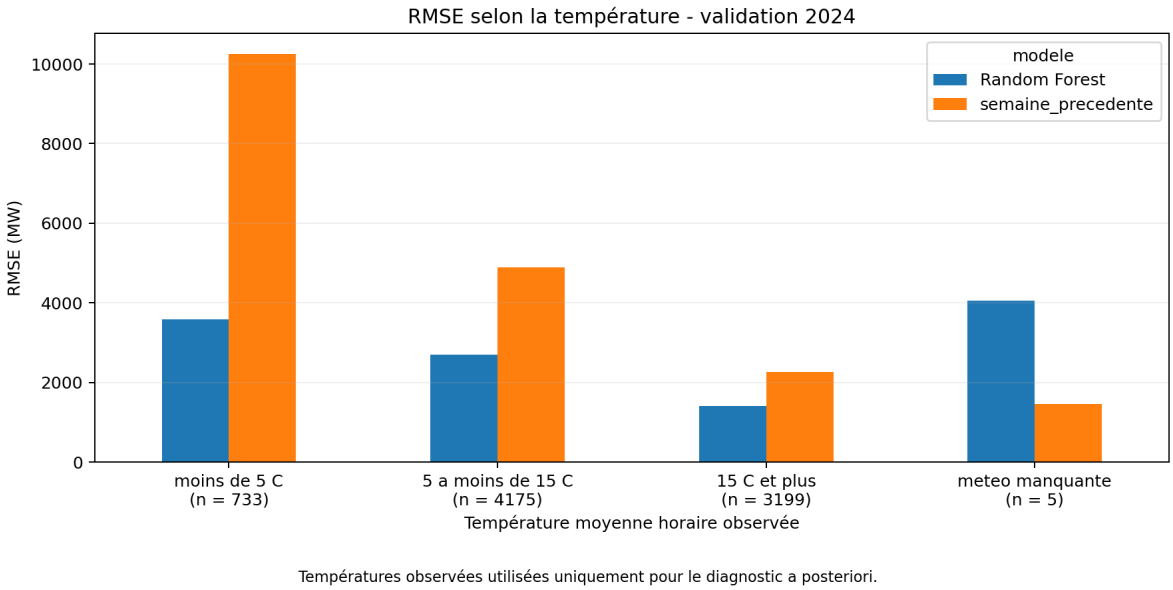


FIGURE 4 – RMSE horaire selon la température observée en validation 2024. Les effectifs indiquent le nombre d'heures dans chaque catégorie.

taines conditions froides. Elles ne démontrent cependant pas, à elles seules, un lien causal entre la température et l'ampleur des erreurs.

Les catégories inférieure à 5 °C, comprise entre 5 et moins de 15 °C et supérieure ou égale à 15 °C regroupent respectivement 733, 4 175 et 3 199 heures.

La catégorie correspondant à une météo manquante ne comprend que cinq heures. Son RMSE est donc particulièrement sensible à quelques observations et ne permet pas de conclure de manière robuste sur les performances des modèles en l'absence de données météorologiques.

3.6 Autocorrélation des erreurs de prévision

L'autocorrélation des erreurs horaires de prévision a été examinée pour les modèles AR(1), AR(2) et ARMA(1,1). Le diagnostic est calculé sur le plus long bloc temporel continu de validation, comprenant 4 320 heures.

Les fonctions d'autocorrélation révèlent une dépendance temporelle importante des erreurs, particulièrement aux premiers retards. Cette dépendance décroît progressivement, mais des structures temporelles persistent aux retards intermédiaires.

Les tests de Ljung–Box réalisés aux retards de 24 et 168 heures conduisent, pour les trois modèles, au rejet de l'hypothèse nulle d'absence d'autocorrélation jusqu'aux retards considérés, avec des valeurs de p inférieures à 0,001.

Ces résultats indiquent que les erreurs de prévision conservent une structure temporelle exploi-

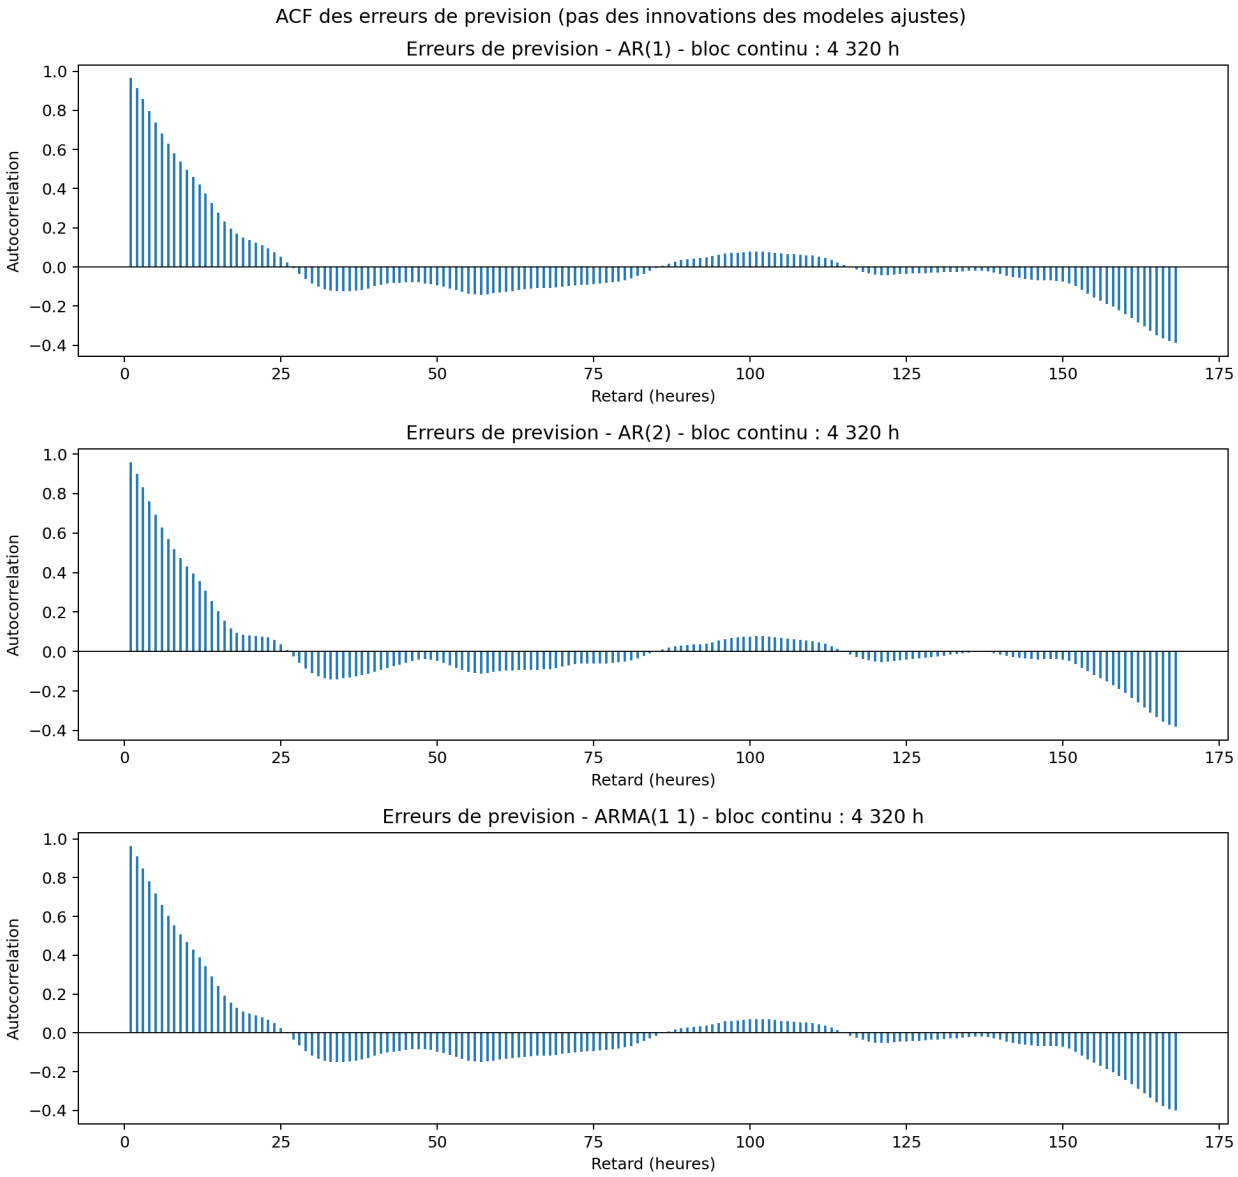


FIGURE 5 – Fonctions d'autocorrélation des erreurs de prévision horaires des modèles statistiques sur le plus long bloc continu de validation 2024.

table, qui n'est pas entièrement capturée par les modèles étudiés.

Il convient toutefois de distinguer les erreurs de prévision évaluées ici des innovations des modèles ajustés. Les premières résultent de prévisions à plusieurs horizons et ne constituent pas directement les résidus d'ajustement à un pas. Ces diagnostics ne doivent donc pas être interprétés comme un test de blancheur des innovations des modèles AR et ARMA.

3.7 Analyse de trois journées difficiles

Les trois journées présentant les plus fortes RMSE quotidiennes pour la forêt aléatoire sont le 24 décembre, le 21 novembre et le 19 janvier 2024 (figure 6).

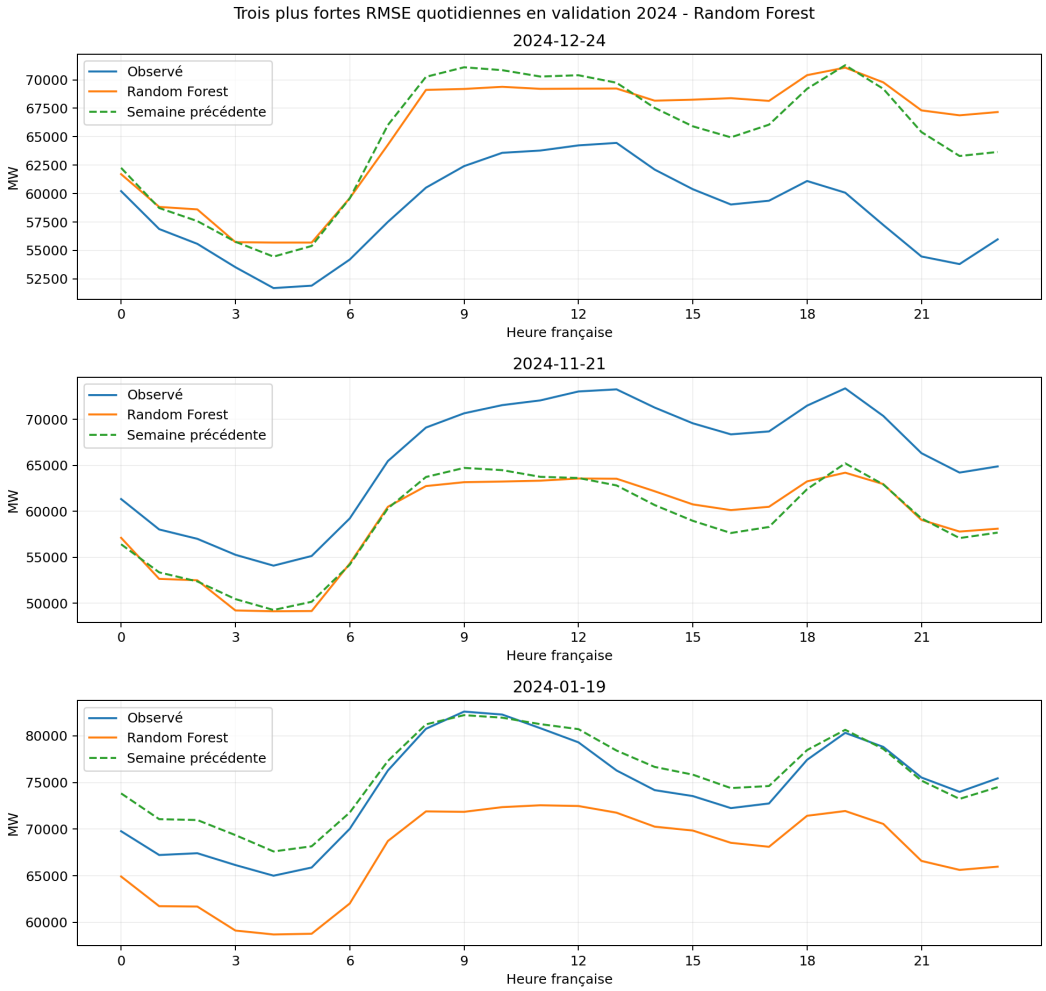


FIGURE 6 – Trois journées présentant les RMSE quotidiennes les plus élevées pour la forêt aléatoire en validation 2024.

Le 24 décembre, la consommation est surestimée de 6 958 MW en moyenne. Cette date n'est pas un jour férié officiel, mais sa proximité avec Noël pourrait contribuer à un comportement de consommation particulier. Cette hypothèse reste à vérifier.

Le 21 novembre et le 19 janvier, la consommation est sous-estimée de respectivement 7 118 MW et 6 940 MW en moyenne. Pour ces journées, les conditions météorologiques et les historiques disponibles avant la prévision peuvent être examinés pour mieux comprendre les erreurs.

Dans les trois cas, le modèle reproduit globalement la forme du profil journalier, mais prévoit un niveau de consommation trop élevé ou trop faible.

Le 19 janvier illustre particulièrement cette limite : malgré une meilleure performance globale sur la validation, la forêt aléatoire peut commettre une erreur plus importante qu'un benchmark simple sur certaines journées.

Ces résultats décrivent la validation de 2024, déjà consultée lors des expériences. Ils ne constituent pas une évaluation indépendante sur le test final de 2025, qui reste réservé.

4 Discussion

4.1 Disponibilité des données et risques de fuite

4.2 Analyse de trois journées d'échec

4.3 Robustesse et limites des modèles

4.4 Trois exemples documentés d'usage des agents IA

Références

Augusti, A. (2026). *Vacances scolaires par zones* [Jeu de données, dernière mise à jour le 29 octobre 2026]. data.gouv.fr. Récupérée novembre 5, 2026, à partir de https://www.data.gouv.fr/datasets/vacances-scolaires-par-zones/informations

Gouvernement français. (2026). *Jours fériés en France métropolitaine* [Jeu de données, dernière mise à jour le 2 octobre 2026]. data.gouv.fr. Récupérée novembre 5, 2026, à partir de https://www.data.gouv.fr/datasets/jours-feries-en-france-metropolitaine

Météo-France. (2026). Données SYNOP essentielles OMM [Consulté le 04-11-2026].

RTE. (2026). éCO2mix : Les données de l'électricité en temps réel [Consulté le 04-11-2026].