Watt's demain : Algorithme de prédiction des données de consommation électrique française

Melissa Aliouche, Nada Haddad, Lola Cusin
M2 Machine Learning for artifical Intelligence (MALIA)

11/11/2026

Cours : Temporal Data Analysis
Enseignant : Jairo Cugliari

Table des matières

1 Introduction **1**

2 Méthodes **1**

2.1 Données et question de prévision 1

2.2 Protocole temporel et disponibilité 2

2.3 Références et modèles statistiques 2

2.4 Modèles ML et critères d'évaluation 3

3 Résultats **3**

3.1 Exploration et couverture des données 3

3.2 Validation 2024 et choix du modèle 4

3.3 Hétérogénéité et journées difficiles en 2024 5

3.4 Test final indépendant 2025 6

4 Discussion **8**

4.1 Disponibilité des données et risques de fuite 8

4.2 Analyse de trois journées d'échec 9

4.3 Robustesse et limites des modèles 9

4.4 Trois exemples documentés d'usage des agents IA 9

4.4.1 Proposition conservée : création des benchmarks 10

4.4.2 Proposition modifiée : optimisation du code ML 10

4.4.3 Faiblesse détectée : erreurs dans le code généré par l'assistant 10

Références **11**

1 Introduction

Afin d'assurer le bon fonctionnement du réseau électrique, il est nécessaire d'avoir un équilibre entre la production et la consommation d'électricité. La consommation d'électricité est influencée par de nombreux facteurs, tels que la météo, les habitudes de consommation des ménages et des entreprises, et les événements spéciaux. La prévision de la consommation d'électricité est donc un enjeu crucial pour les gestionnaires de réseau : elle permet d'anticiper les besoins, de planifier la production et donc de de garantir la stabilité du système électrique.

Afin de suivre la consommation électrique en temps réel, le Réseau de Transport d'Électricité RTE collecte les données de consommation à l'aide de télémesures transmises directement depuis ses installations (RTE, 2026). Certains de ses sites ne sont pas équipé pour la télémesures, les données sont donc complétées par des estimations, remplacées par la suite par des données de comptage plus complètes. RTE propose également des prévisions de consommation à court terme, qui sont utilisées pour planifier la production et la distribution d'électricité. Ces prévisions sont basées sur des modèles statistiques et des algorithmes d'apprentissage automatique, qui prennent en compte les données historiques de consommation, les conditions météorologiques et d'autres facteurs pertinents.

L'objectif de ce rapport est de proposer un algorithme de prédiction de la consommation électrique française à court terme, en utilisant les données de consommation collectées par RTE. Nous allons explorer différentes approches de modélisation, en utilisant des techniques d'apprentissage automatique et d'analyse de séries temporelles, afin d'obtenir des prévisions précises et fiables. Nous allons également évaluer les performances de notre algorithme en le comparant à nos méthodes de référence, modèles statistiques et modèles de machine learning, et en analysant les erreurs de prévision pour identifier les points faibles et les opportunités d'amélioration. Nos prédictions s'appuieront sur les données historiques compilées par RTE, ainsi que sur les données météorologiques du réseau SYNOP (Météo-France, 2026), et le calendrier des jours fériés et vacances scolaires en France.

2 Méthodes

2.1 Données et question de prévision

À 14 h le jour J, nous prévoyons les 24 puissances moyennes horaires $C_{J+1,h}$ (MW) de la France métropolitaine. Les données proviennent d'éCO2mix, des observations SYNOP et du calendrier des jours fériés et vacances (Augusti, 2026 ; Gouvernement français, 2026 ; Météo-France, 2026 ; RTE, 2026). La consommation horaire est la moyenne des mesures RTE à :00 et :30, datée en début d'heure. Parmi les stations métropolitaines, nous retenons celles dont les couvertures en température et précipitations dépassent chacune 95 % sur 2012–2023. Les relevés contradictoires sont rendus manquants ; les stations disponibles ont le même poids dans la moyenne nationale. Leur écart-type mesure une dispersion spatiale, pas l'incertitude sur une moyenne nationale.

La température est interpolée entre deux mesures SYNOP espacées de trois heures et le cumul de pluie est réparti sur les trois heures qui précèdent sa mesure finale. La consommation et le calendrier sont en heure civile française ; les jointures météo passent par l'UTC. La pluie datée à h concerne $[h, h+1]$. Les fichiers RTE gardent 24 étiquettes aux changements d'heure : nous masquons les mesures des jours concernés, tout en conservant la grille de lignes et l'espacement des retards.

L'exploration de 2012–2023 décrit l'évolution des moyennes journalières, les profils journaliers et hebdomadaires, la saisonnalité annuelle et les ACF/PACF. Nous examinons aussi $Y_t = C_t - C_{t-168}$, qui soustrait la même heure de la semaine précédente ; cette opération n'assure pas à elle seule la stationnarité.

2.2 Protocole temporel et disponibilité

L'apprentissage initial porte sur 2012–2023 et la comparaison des dix méthodes sur 2024 ; 2025 est réservé au test final. Chaque prévision est simulée à J 14 h, avec la consommation observée au plus tard à J 8 h (hypothèse prudente, non vérifiée pour toutes les publications historiques RTE). Le calendrier de $J+1$ est connu d'avance. Pour la météo horaire, la reconstruction peut nécessiter la mesure SYNOP suivante : nous ne retenons que les valeurs dont cette mesure serait disponible à J 14 h *si* son délai de publication est de trois heures. Ce délai est une hypothèse, et non une disponibilité historique vérifiée. Aucune météo observée pendant $J+1$ n'entre dans les prédicteurs.

Les mêmes journées complètes sont exigées pour les dix méthodes en 2024 : cible et historiques nécessaires observés, dont les quatre semaines des benchmarks ; les changements d'heure et certaines journées qui les suivent sont ainsi exclus. Les modèles de machine learning (ML) sont ajustés une fois sur les cibles admissibles jusqu'au 30 décembre 2023. Pour les modèles AR/ARMA, les paramètres sont estimés avant 2024, puis les états sont mis à jour uniquement avec les observations disponibles avant chaque origine, sans réestimation pendant 2024.

La forêt aléatoire est choisie sur la RMSE de validation 2024. Après ce choix, elle seule est réentraînée, sans changer ses variables ni ses paramètres, sur les cibles admissibles de 2012 jusqu'au 30 décembre 2024, puis évaluée sur les journées admissibles de 2025. Les prédictions de 2025 ne servent à aucun réglage.

2.3 Références et modèles statistiques

Pour une heure cible t et la dernière heure de consommation connue c, nous utilisons la persistance $\widehat{C}_t = C_c$, la semaine précédente $\widehat{C}_t = C_{t-168}$ et la moyenne de quatre semaines $\widehat{C}_t = \frac{1}{4}\sum_{k=1}^{4} C_{t-168k}$. Toutes les valeurs historiques requises doivent exister.

Nous ajustons sur $Y_t = C_t - C_{t-168}$ les modèles AR(1), AR(2) et ARMA(1,1), sans constante. Pour ARMA(1,1), $Y_t = \phi_1 Y_{t-1} + \varepsilon_t + \theta_1 \varepsilon_{t-1}$; AR(1) et AR(2) ne conservent que les termes autorégressifs correspondants. Après prévision, $\widehat{C}_t = C_{t-168} + \widehat{Y}_t$. Les paramètres sont estimés par maximum de

vraisemblance. Pour des modèles ajustés à la même série transformée, nous comparons aussi $\mathrm{AIC} = -2\ell(\widehat{\theta}) + 2k$ et $\mathrm{BIC} = -2\ell(\widehat{\theta}) + k \log n$, où k compte les paramètres et n les observations retenues. Ces critères d'ajustement ne remplacent pas les erreurs de prévision hors échantillon.

2.4 Modèles ML et critères d'évaluation

Nous comparons une régression linéaire multiple, Ridge ($\alpha = 100$), une forêt aléatoire (100 arbres, profondeur maximale 15, au moins trois observations par feuille, graine 42) et un gradient boosting (80 arbres, profondeur maximale 2, taux 0,08). Les variables sont le calendrier et l'heure cible, la consommation de J entre 0 et 8 h, ainsi que des statistiques et valeurs horaires de consommation et météo des jours $J-1$, $J-7$, $J-14$ et $J-28$. La météo historique de J est limitée aux mesures disponibles à l'origine. Les valeurs manquantes sont imputées par la médiane apprise sur l'entraînement ; les deux régressions utilisent aussi une standardisation apprise sur cette période. Les configurations sont fixes, sans recherche systématique d'hyperparamètres.

Pour N heures et $e_t = C_t - \widehat{C}_t$, nous calculons $\mathrm{MAE} = N^{-1} \sum_t |e_t|$, $\mathrm{RMSE} = \sqrt{N^{-1} \sum_t e_t^2}$ et le biais $N^{-1} \sum_t e_t$ (négatif en cas de surestimation). Nous examinons aussi l'énergie quotidienne $\sum_{h=0}^{23} C_{J+1,h} \times 1\,\mathrm{h}$, la valeur et l'heure de la pointe, les résultats par saison et conditions, ainsi que les trois plus fortes RMSE quotidiennes en validation 2024. En cas d'égalité sur la pointe, sa première occurrence est retenue.

3 Résultats

3.1 Exploration et couverture des données

Les critères de couverture retiennent 37 stations SYNOP. Sur la grille géographique utilisée, 45,1 % de la surface métropolitaine est à moins de 50 km d'une station et 97,3 % à moins de 100 km (distance médiane : 53,0 km). La carte montre une proximité géographique, sans démontrer une représentativité climatique ou démographique.

Les profils moyens sur l'apprentissage 2012–2023 mettent en évidence les cycles journalier et hebdomadaire (figure 2). La consommation moyenne par mois est plus élevée en hiver qu'en été ; les mois froids coïncident aussi avec les consommations les plus fortes. Le graphique comparant les vacances scolaires montre des niveaux médians différents, sans isoler leur effet de celui de la saison ou du jour de la semaine. Ces constats descriptifs motivent les variables calendaires et météorologiques. La différence à 168 h atténue certains motifs hebdomadaires, sans éliminer nécessairement la tendance ni rendre la série stationnaire.

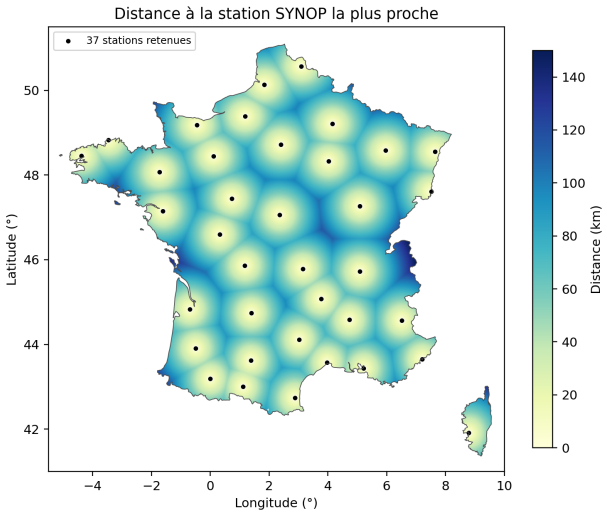
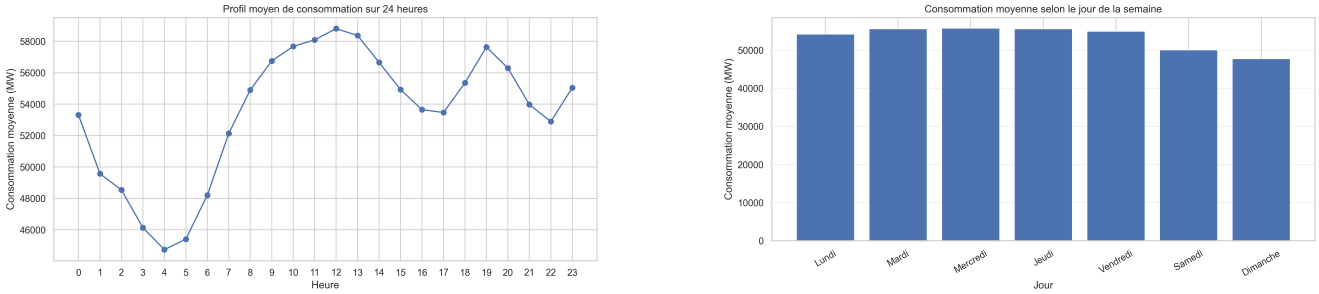


FIGURE 1 – Distance à la station SYNOP retenue la plus proche.



(a) Cycle journalier.

(b) Cycle hebdomadaire.

FIGURE 2 – Consommation moyenne selon l'heure et le jour, 2012–2023.

3.2 Validation 2024 et choix du modèle

Les dix méthodes sont comparées sur les mêmes 338 journées admissibles de 2024, soit 8 112 heures ; 28 journées ne satisfont pas les critères de disponibilité, notamment autour des changements d'heure. Le tableau 1 donne les erreurs horaires, en MW, avec $e_t = C_t - \widehat{C}_t$.

La forêt aléatoire a les plus faibles MAE et RMSE : par rapport à la semaine précédente, la RMSE baisse de 51,2 %. La régression linéaire est deuxième en RMSE (2 686 MW). Parmi les modèles statistiques, ARMA(1,1) prédit légèrement mieux qu'AR(2) (3 291 contre 3 298 MW), alors que les AIC/BIC d'AR(2) sont plus faibles : AIC de 1 576 213 et BIC de 1 576 242, contre 1 578 311 et 1 578 340 pour ARMA(1,1). L'ajustement sur l'apprentissage ne détermine donc pas à lui seul la qualité hors échantillon. La forêt obtient une erreur absolue quotidienne d'énergie de 33 478 MWh et une erreur absolue sur la valeur de pointe de 1 818 MW ; la régression linéaire fait légèrement mieux pour ces deux critères (33 342 MWh et 1 633 MW).

L'ablation de la forêt aléatoire (figure 3) donne une RMSE de 6 031,15 MW avec le seul calendrier,

TABLEAU 1 – Scores horaires de validation 2024 sur les 8 112 mêmes heures (MW).

Méthode	MAE	RMSE	Biais
Forêt aléatoire	1 644	2 383	-146
Régression linéaire	2 015	2 686	-390
Ridge	2 041	2 733	-297
Gradient boosting	2 324	3 093	-647
ARMA(1,1)	2 147	3 291	89
AR(2)	2 177	3 298	114
AR(1)	2 230	3 408	80
Semaine précédente	3 214	4 888	257
Moyenne de quatre semaines	3 705	5 413	291
Persistance	5 659	7 056	-778

2 387,66 MW en ajoutant l'historique de consommation, et 2 383,19 MW en ajoutant la météo passée. Le gain apporté par cette météo historique est de 4,47 MW (0,19 % de la RMSE précédente) ; sa signification statistique n'a pas été évaluée. Il ne permet pas de conclure à l'absence d'un effet physique de la météo.

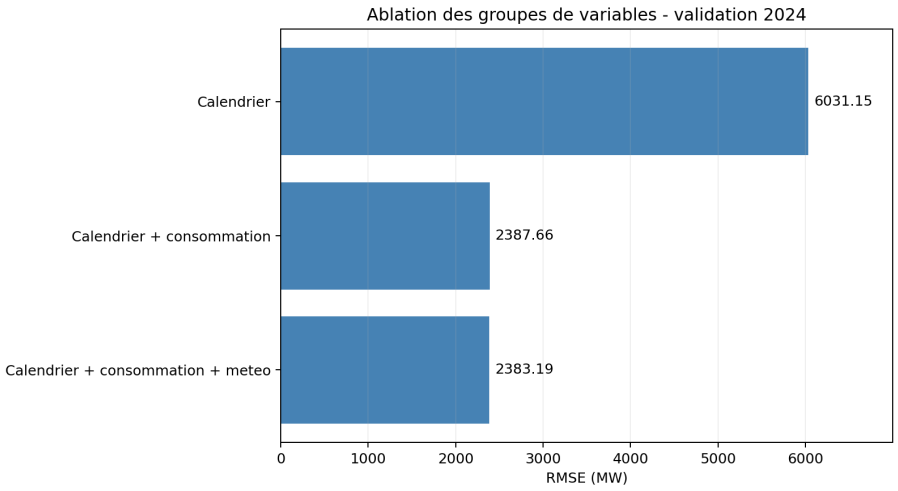


FIGURE 3 – Ablation des familles de variables en validation 2024 (RMSE).

3.3 Hétérogénéité et journées difficiles en 2024

La RMSE de la forêt est de 3 546 MW en hiver contre 1 065 MW en été ; elle atteint 3 175 MW sur les jours fériés et 2 361 MW sur les autres jours. Seuls huit jours fériés sont évalués. Par température observée, les catégories moins de 5 °C, 5 à moins de 15 °C et au moins 15 °C comptent respectivement 733, 4 175 et 3 199 heures ; cinq heures ont une météo manquante. La forêt fait mieux que le benchmark hebdomadaire dans les trois classes renseignées. Ces températures observées ne servent qu'au diagnostic a posteriori, pas à la prévision de $J + 1$.

Sur le plus long bloc continu de 4 320 heures, les ACF des *erreurs de prévision* des AR/ARMA

conservent une dépendance ; les tests de Ljung–Box aux retards 24 et 168 h rejettent l'absence d'autocorrélation ($p < 0{,}001$). Ces erreurs à plusieurs horizons ne sont pas les innovations à un pas du modèle ajusté.

Les trois journées de plus forte RMSE quotidienne pour la forêt, choisies sur la validation 2024, sont le 24 décembre (surestimation moyenne de 6 958 MW), le 21 novembre et le 19 janvier (sous-estimations de 7 118 et 6 940 MW). La figure 4 illustre ces écarts de niveau malgré des profils horaires globalement suivis. Le 24 décembre n'est pas férié officiellement ; son voisinage de Noël est une explication possible, non démontrée.

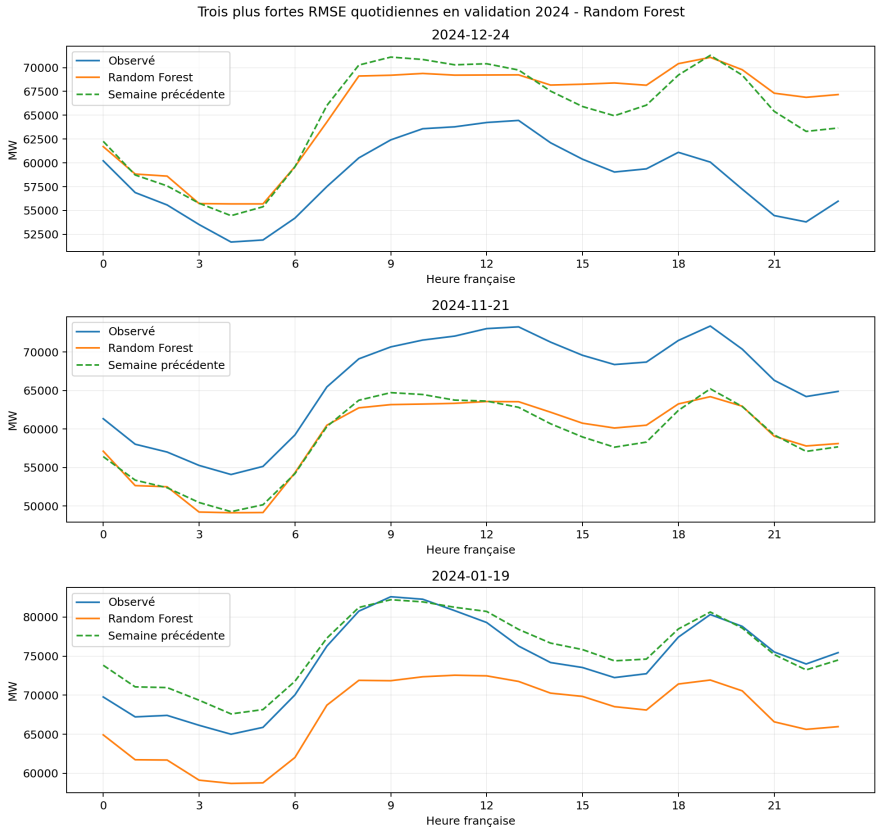


FIGURE 4 – Trois journées de validation 2024 aux plus fortes RMSE quotidiennes de la forêt aléatoire.

3.4 Test final indépendant 2025

Après sélection sur 2024 et réentraînement sur l'historique disponible avant 2025, seule la forêt aléatoire est évaluée en 2025 : 337 journées admissibles, soit 8 088 heures. Les périodes et effectifs diffèrent entre validation et test ; la comparaison du tableau 2 décrit la stabilité observée, sans mesurer un gain causal dû au réentraînement.

La figure 6 compare les *moyennes journalières* des observations et des 24 prévisions horaires sur

TABLEAU 2 – Forêt aléatoire : validation et test final, erreurs horaires en MW.

Période	Journées	MAE	RMSE	Biais
Validation 2024	338	1 644,14	2 383,19	$-145,94$
Test 2025	337	1 619,14	2 306,95	$-20,20$

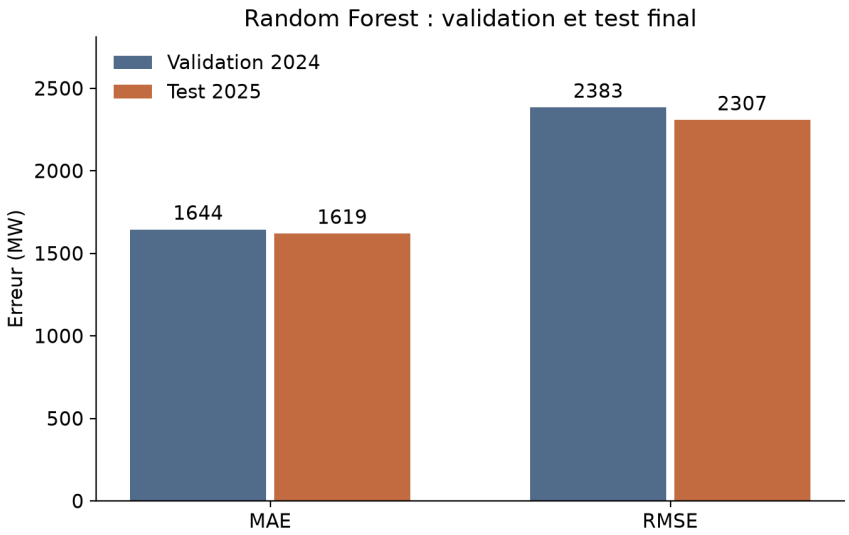


FIGURE 5 – MAE et RMSE de la forêt aléatoire en validation 2024 et en test 2025.

les journées effectivement évaluées en 2025. Les journées exclues ne sont pas interpolées. Pour montrer la forme horaire, la figure 7 présente quatre semaines calendaires complètes admissibles, choisies vers le milieu des mois visés sans regarder les erreurs. Aucune semaine complète d'avril ne satisfait ce critère : la semaine du 5 au 11 mai représente donc le printemps. Ces exemples visuels ne suffisent pas à établir des scores saisonniers pour 2025.

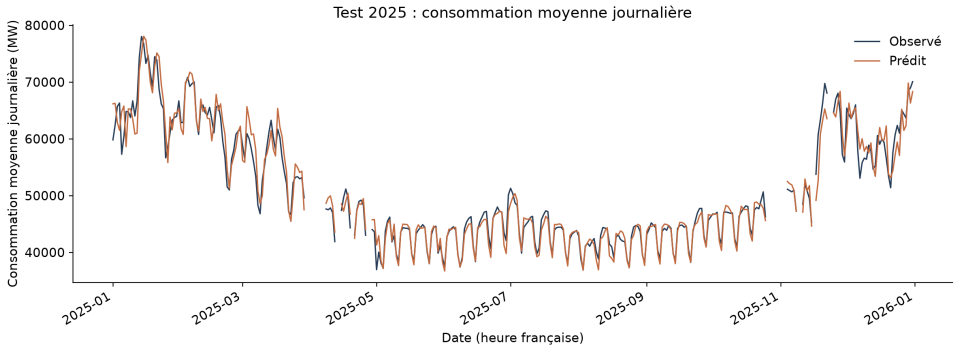


FIGURE 6 – Consommations moyennes journalières observées et prédites sur les journées admissibles de 2025 (MW).

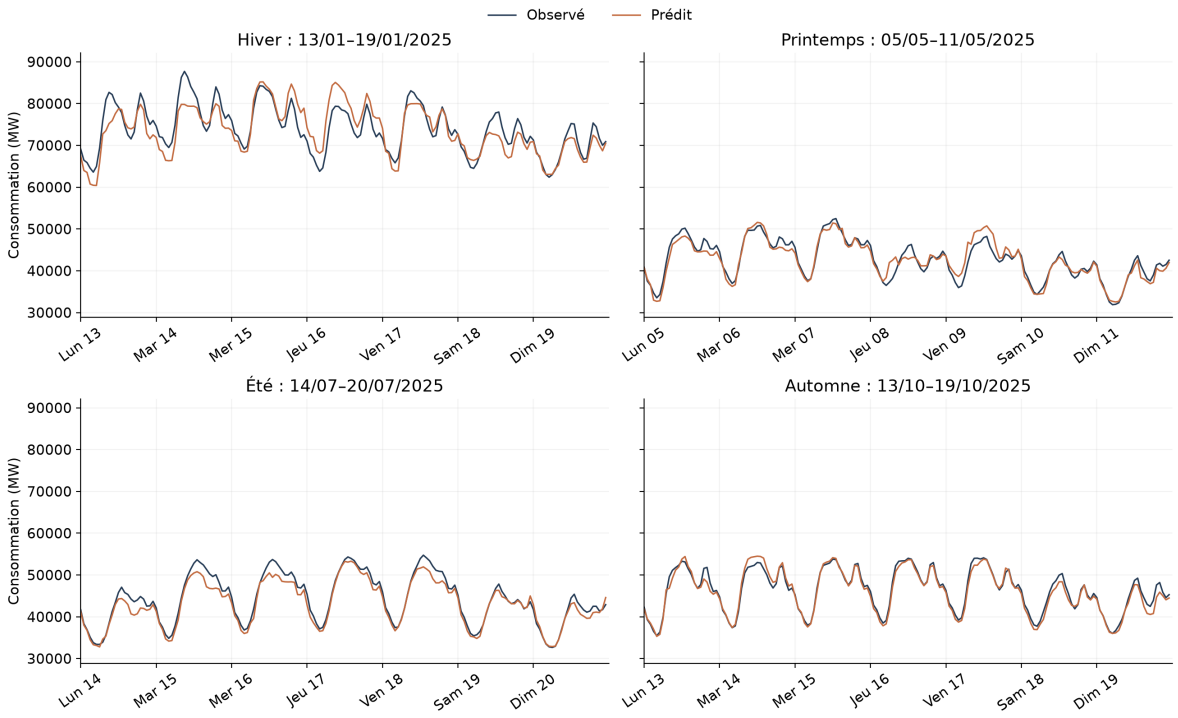


FIGURE 7 – Valeurs horaires observées et prédites : hiver (13–19 janvier), printemps (5–11 mai), été (14–20 juillet), automne (13–19 octobre 2025). Échelle verticale commune.

4 Discussion

4.1 Disponibilité des données et risques de fuite

Le contrôle temporel porte sur l'origine J 14 h, et non sur la date de téléchargement des archives. Le tableau 3 sépare les informations connues à l'avance des observations dont l'heure effective de publication historique reste incertaine.

TABLEAU 3 – Informations utilisées à l'origine de prévision J 14 h.

Variable	Source	Disponibilité à J 14 h	Statut et usage	Risque de fuite
Calendrier de $J+1$	Calendrier construit	Connu à l'avance.	Connue ; prédicteur.	Aucune observation future.
Consommation passée	RTE éCO2mix	Jusqu'à J 8 h ; publication historique non vérifiée.	Observée ; retards et statistiques.	Si publiée après 14 h.
Météo passée	SYNOP	Mesure nécessaire supposée publiée sous trois heures ; délai non vérifié.	Observée, reconstruite ; prédicteur.	Si la mesure suivante arrive après 14 h.
Consommation de $J+1$	RTE éCO2mix	Inconnue à J 14 h.	Observée après coup ; cible seule.	Si employée comme prédicteur.

La météo observée pendant $J+1$ reste exclue des prédicteurs.

Les changements d'heure compliquent l'identification des instants dans les 24 étiquettes RTE ; masquer les jours ambigus évite de comparer des heures mal alignées, mais réduit le nombre de journées évaluables. La comparaison 2024 utilise les mêmes dates pour dix méthodes. Après sélection de la forêt sur 2024, 2025 reste indépendant pour l'évaluation de *ce seul modèle* ; ses scores ne doivent pas servir à le régler.

4.2 Analyse de trois journées d'échec

Le 24 décembre 2024, la forêt surestime la demande moyenne de 6 958 MW : la consommation observée est de 58 505 MW, contre 64 958 MW une semaine auparavant. La proximité de Noël pourrait jouer un rôle, sans que ces chiffres établissent une cause. Le 21 novembre, elle sous-estime de 7 118 MW ; la demande observée atteint 66 002 MW, contre 58 747 MW sept jours plus tôt. Le 19 janvier, elle sous-estime de 6 940 MW alors que la demande observée (74 332 MW) est inférieure à celle d'une semaine auparavant (75 747 MW). Ces écarts montrent que la seule comparaison hebdomadaire ne suffit pas à expliquer les trois erreurs. Les profils horaires sont généralement suivis, mais le niveau prévu est décalé ; les données disponibles ne permettent pas d'attribuer chaque échec à une cause unique.

4.3 Robustesse et limites des modèles

La forêt gagne nettement face aux benchmarks sur 2024 ; dans l'ablation, l'ajout de l'historique de consommation apporte la plus forte baisse de RMSE, alors que celui de la météo *passée* n'apporte que 4,47 MW de gain supplémentaire. Son classement dépend néanmoins du critère : la régression linéaire fait légèrement mieux sur l'énergie quotidienne et la valeur de la pointe. Les erreurs hivernales dépassent celles de l'été ; les huit jours fériés évalués ne permettent pas une conclusion solide sur l'ensemble des jours fériés. Les erreurs AR/ARMA sont autocorrélées, mais leur ACF n'est pas un diagnostic direct de leurs innovations ajustées.

Après réentraînement sans nouveau réglage, la RMSE de la forêt est de 2 306,95 MW en 2025 contre 2 383,19 MW en 2024 : les erreurs globales restent du même ordre sur deux années et ensembles de journées distincts. Cette comparaison ne prouve ni une robustesse uniforme selon les saisons, ni un effet causal du réentraînement. Nous déconseillerions une utilisation sans précaution lors des changements d'heure, des journées atypiques proches des fêtes ou des fortes demandes hivernales. Les délais historiques réels de publication, l'agrégation de stations à poids égaux et l'absence de prévisions météo pour $J + 1$ limitent aussi la portée d'un déploiement réel.

4.4 Trois exemples documentés d'usage des agents IA

Dans le cadre de notre projet Watts Demain, nous avons utilisé ChatGPT pour nous aider à comprendre certains codes, améliorer leur implémentation et vérifier nos méthodes.

Nous présentons trois exemples de son utilisation.

4.4.1 Proposition conservée : création des benchmarks

Tâche demandée : Nous avons demandé de l'aide pour construire deux benchmarks : la consommation de la semaine précédente et la moyenne des quatre semaines précédentes.

Proposition obtenue : Utiliser la fonction `shift()` de pandas pour récupérer les consommations des jours précédents.

Décision prise : Nous avons conservé cette méthode dans notre code.

Vérification : Nous avons vérifié que les décalages correspondaient aux bonnes dates et que les prévisions étaient calculées uniquement à partir des consommations passées.

4.4.2 Proposition modifiée : optimisation du code ML

Tâche demandée : Nous souhaitions améliorer notre code Machine Learning, car la création des variables explicatives était lente.

Proposition obtenue : Remplacer certaines boucles par des opérations pandas plus efficaces, comme `groupby()` et `merge()`.

Décision prise : Nous avons modifié notre code ML.py en suivant cette proposition.

Vérification : Nous avons exécuté le nouveau code et vérifié la création des variables, les dimensions des données et le bon fonctionnement des modèles.

4.4.3 Faiblesse détectée : erreurs dans le code généré par l'assistant

Tâche demandée : Nous avons utilisé ChatGPT pour nous aider à développer et corriger des scripts Python du projet.

Réponse obtenue : L'assistant a parfois proposé du code contenant des erreurs, notamment en utilisant des noms de variables ou de colonnes qui ne correspondaient pas à ceux de nos fichiers. Certaines propositions ne répondaient pas non plus exactement à notre demande.

Décision prise : Nous avons corrigé ou adapté ces propositions pour les rendre compatibles avec notre projet.

Vérification : Nous avons comparé les codes proposés avec nos fichiers existants, vérifié les noms des variables et des colonnes, puis exécuté les scripts pour détecter et corriger les erreurs.

Références

Augusti, A. (2026). *Vacances scolaires par zones* [Jeu de données, dernière mise à jour le 29 octobre 2026]. data.gouv.fr. Récupérée octobre 30, 2026, à partir de https://www.data.gouv.fr/datasets/vacances-scolaires-par-zones/informations

Gouvernement français. (2026). *Jours fériés en France métropolitaine* [Jeu de données, dernière mise à jour le 2 octobre 2026]. data.gouv.fr. Récupérée octobre 15, 2026, à partir de https://www.data.gouv.fr/datasets/jours-feries-en-france-metropolitaine

Météo-France. (2026). *Données SYNOP essentielles OMM* [Jeu de données]. Récupérée octobre 15, 2026, à partir de https://www.data.gouv.fr/datasets/observations-meteorologiques-historiques-france-synop

RTE. (2026). *éCO2mix : Les données de l'électricité en temps réel* [Jeu de données]. Récupérée octobre 15, 2026, à partir de https://www.rte-france.com/donnees-publications/eco2mix-donnees-temps-reel/consommation-france