Watt's demain : Algorithme de prédiction des données de consommation électrique française

Melissa Aliouche, Nada Haddad, Lola Cusin
M2 Machine Learning for artifical Intelligence (MALIA)

11/11/2026

Cours : Temporal Data Analysis
Enseignant : Jairo Cugliari

Table des matières

1 Introduction **1**

2 Méthodes **1**

2.1 Données et préparation horaire 1

2.2 Exploration et décomposition 2

2.3 Modèles de référence et modèles du cours 3

2.3.1 Benchmarks 3

2.3.2 AR, MA et ARMA 4

2.3.3 Estimation et évaluation chronologique 4

2.4 Modèles d'apprentissage supervisé (ML) 5

2.4.1 Régression linéaire multiple : modèle M09 5

2.4.2 Variantes, ablations et décomposition descriptive 6

2.4.3 Correction des résidus et prévision du lendemain 7

3 Résultats **8**

3.1 Données préparées et analyse descriptive 8

3.2 Comparaison des décompositions 9

3.3 Modèles du cours : AR, MA et ARMA 10

3.4 Modèles d'apprentissage supervisé (ML) 11

3.4.1 Régression M09 : variables et ablations 11

3.4.2 Résidus et correction autorégressive 12

3.4.3 Validation 2024 selon le scénario météo 13

4 Discussion **13**

4.1 Disponibilité des données et risques de fuite 14

4.2 Analyse de trois journées d'échec 14

4.3 Robustesse et limites des modèles 14

4.4 Trois exemples documentés d'usage des agents IA 14

Références **15**

1 Introduction

Afin d'assurer le bon fonctionnement du réseau électrique, il est nécessaire d'avoir un équilibre entre la production et la consommation d'électricité. La consommation d'électricité est influencée par de nombreux facteurs, tels que la météo, les habitudes de consommation des ménages et des entreprises, et les événements spéciaux. La prévision de la consommation d'électricité est donc un enjeu crucial pour les gestionnaires de réseau : elle permet d'anticiper les besoins, de planifier la production et donc de de garantir la stabilité du système électrique.

Afin de suivre la consommation électrique en temps réel, le Réseau de Transport d'Électricité RTE collecte les données de consommation à l'aide de télémesures transmises directement depuis ses installations (RTE, 2026). Certains de ses sites ne sont pas équipé pour la télémesures, les données sont donc complétées par des estimations, remplacées par la suite par des données de comptage plus complètes. RTE propose également des prévisions de consommation à court terme, qui sont utilisées pour planifier la production et la distribution d'électricité. Ces prévisions sont basées sur des modèles statistiques et des algorithmes d'apprentissage automatique, qui prennent en compte les données historiques de consommation, les conditions météorologiques et d'autres facteurs pertinents.

L'objectif de ce rapport est de proposer un algorithme de prédiction de la consommation électrique française à court terme, en utilisant les données de consommation collectées par RTE. Nous allons explorer différentes approches de modélisation, en utilisant des techniques d'apprentissage automatique et d'analyse de séries temporelles, afin d'obtenir des prévisions précises et fiables. Nous allons également évaluer les performances de notre algorithme en le comparant aux prévisions existantes de RTE, et en analysant les erreurs de prévision pour identifier les points faibles et les opportunités d'amélioration. Nos prédictions s'appuieront sur les données historiques compilées par RTE, ainsi que sur les données météorologiques du réseau SYNOP (Météo-France, 2026), et le calendrier des jours fériés et vacances scolaires en France.

2 Méthodes

2.1 Données et préparation horaire

L'objectif est de prévoir, à 14 h le jour J en heure française, les 24 puissances moyennes horaires de $J+1$. Les données de consommation étudiées couvrent 2012–2025. Elles sont associées aux observations SYNOP et aux indicateurs de calendrier présentés dans le tableau 1. La consommation est une puissance en MW, et non une énergie en MWh.

Les sources sont éCO2mix, SYNOP et les référentiels des jours fériés et des vacances par zone (Augusti, 2026 ; Gouvernement français, 2026 ; Météo-France, 2026 ; RTE, 2026). Les doublons SYNOP exacts sont supprimés ; les valeurs contradictoires pour une même station et un même instant deviennent manquantes. Les stations métropolitaines doivent présenter une couverture strictement supérieure à

TABLEAU 1 – Données utilisées et transformations principales.

Données	Pas initial	Préparation
Consommation RTE	30 minutes	Moyenne des puissances à :00 et :30, en MW, datée en début d'heure.
Météo SYNOP	3 heures	Température en °C et précipitations en mm, reconstruites au pas horaire.
Calendrier	1 jour	Heure, jour de semaine, jours fériés et vacances scolaires par zone.

95 % pour chacune des deux variables. La température est interpolée linéairement entre observations valides séparées de trois heures ; le cumul de pluie est réparti sur les trois heures précédentes. La moyenne des stations disponibles utilise des poids égaux. Leur écart-type spatial n'est pas un intervalle de confiance national.

Les consommations proviennent des fichiers annuels téléchargés directement sur le site éCO2mix. Les dates sont en heure française, conservée pour les jours fériés, les vacances et les profils horaires. Nous ajoutons une date UTC pour joindre la météo. Les réponses de l'API RTE servent seulement de vérification externe. La température utilisée est celle du début de l'heure, T_h. La pluie sur $[h, h+1]$ est déjà datée à h dans l'extraction : aucun décalage supplémentaire n'est appliqué dans la fusion.

Les fichiers RTE conservent 24 étiquettes horaires lors des changements d'heure. Pour les prévisions, nous masquons donc la consommation des deux journées de transition annuelles. Les lignes restent présentes pour conserver les décalages horaires ; les valeurs manquantes ne sont pas remplies. Si la cible ou l'historique nécessaire est incomplet, la journée est exclue pour toutes les méthodes de la comparaison. Les données brutes restent intactes.

La couverture géographique est estimée sur le contour Natural Earth, Corse incluse, par la distance sphérique à la station la plus proche. Une grille de $0{,}005°$ est pondérée par l'aire des cellules et comparée aux maillages $0{,}01°$ et $0{,}02°$. Les seuils de 50 et 100 km décrivent la proximité, sans garantir la représentativité climatique.

2.2 Exploration et décomposition

L'exploration porte uniquement sur 2012–2023. Nous représentons l'évolution de la consommation et ses profils horaires, hebdomadaires et mensuels. Les décompositions classiques sont

$$C_t = m_t + s_t + r_t \quad \text{(additive)}, \qquad C_t = m_t\, s_t\, r_t \quad \text{(multiplicative)}.$$

La composante m_t représente la tendance et les variations lentes, s_t la saisonnalité, et r_t la composante irrégulière. Cette dernière n'est pas nécessairement un bruit blanc. L'amplitude saisonnière est exprimée en MW dans le modèle additif, et proportionnelle au niveau dans le modèle multiplicatif.

Pour la tendance longue, nous calculons la consommation quotidienne moyenne $\overline{C}_d$, puis une

moyenne mobile centrée :

$$\widehat{m}_d = \frac{1}{365} \sum_{j=-182}^{182} \overline{C}_{d+j}.$$

Les 182 jours de chaque bord restent sans estimation. Pour une période paire p, la décomposition classique utilise une moyenne mobile centrée $2 \times p$, avec demi-poids aux extrémités. Nous regroupons ensuite les écarts par position saisonnière (heure, heure de semaine ou mois). Dans le cas additif,

$$q_j = \underset{t:\, t \bmod p = j}{\text{moyenne}} (C_t - \widehat{m}_t), \qquad \widehat{s}_j = q_j - \frac{1}{p} \sum_{i=0}^{p-1} q_i.$$

La médiane est aussi testée à la place de la moyenne. Les coefficients sont centrés à zéro, puis soustraits à la série sans tendance. Dans le cas multiplicatif, les rapports remplacent les écarts et les coefficients sont normalisés pour avoir une moyenne égale à un.

Nous comparons ces méthodes à STL standard et robuste, qui estiment tendance et saisonnalité par lissage LOESS. Les périodes 24 h, 168 h et 12 mois sont étudiées séparément ; la dernière utilise les moyennes mensuelles. La variante robuste réduit le poids des observations éloignées de l'ajustement.

Nous testons aussi $C_t - C_{t-8736}$: 364 jours correspondent à 52 semaines et conservent le jour de semaine. Les références à 8736 ± 1 heures vérifient l'alignement horaire. Des différences à 24 h et 1 h sont ajoutées dans certaines variantes. L'ACF mesure $\rho(h) = \mathrm{Corr}(r_t, r_{t-h})$; la PACF mesure la dépendance restante après prise en compte des retards intermédiaires. Un bruit blanc a une moyenne constante, une variance constante et des autocorrélations nulles aux retards non nuls.

Les comparaisons utilisent les mêmes dates à chaque échelle. Les lissages centrés et STL utilisent le futur : leurs résultats sont descriptifs, pas des prévisions réalisables à 14 h. Cette exploration conserve la grille RTE complète ; les changements d'heure sont exclus ensuite dans les modèles prédictifs.

2.3 Modèles de référence et modèles du cours

2.3.1 Benchmarks

Trois benchmarks représentent les familles du cours : persistance, naïf saisonnier et moyenne historique. Pour l'heure cible t, et la dernière heure autorisée c :

$$\widehat{C}_t^{\text{persistance}} = C_c, \qquad \widehat{C}_t^{\text{semaine}} = C_{t-7\,\text{j}}, \qquad \widehat{C}_t^{4\text{ semaines}} = \frac{1}{4} \sum_{k=1}^{4} C_{t-7k\,\text{j}}.$$

Les références hebdomadaires conservent le jour de semaine et l'heure locale. Les dates sont recherchées explicitement ; une moyenne sur moins de quatre semaines n'est pas autorisée.

2.3.2 AR, MA et ARMA

La première comparaison porte sur AR(1), AR(2), MA(1) et ARMA(1,1), les quatre candidats proposés dans les slides de modélisation. Ils sont ajustés à la même série transformée :

$$z_t = (1 - B)(1 - B^{24})C_t = C_t - C_{t-1} - C_{t-24} + C_{t-25},$$

où $BC_t = C_{t-1}$. Les modèles ajustés à z_t s'écrivent :

$$\begin{aligned}
&\mathrm{AR}(1) && : z_t = \phi_1 z_{t-1} + \varepsilon_t,\\
&\mathrm{AR}(2) && : z_t = \phi_1 z_{t-1} + \phi_2 z_{t-2} + \varepsilon_t,\\
&\mathrm{MA}(1) && : z_t = \varepsilon_t + \theta_1 \varepsilon_{t-1},\\
&\mathrm{ARMA}(1,1) && : z_t = \phi_1 z_{t-1} + \varepsilon_t + \theta_1 \varepsilon_{t-1}.
\end{aligned}$$

Les termes AR utilisent les valeurs passées de la série transformée ; les termes MA utilisent les innovations passées ε_t, supposées de moyenne nulle et de variance constante. Un MA(1) n'est donc pas une moyenne mobile des consommations observées. Les différences visent respectivement la persistance lente et le cycle quotidien ; leur pertinence doit être vérifiée par les diagnostics et la prévision. Il ne s'agit pas d'une garantie de stationnarité. Les coefficients sont estimés par maximum de vraisemblance gaussienne, sans constante, sous contraintes de stationnarité et d'inversibilité. Les ACF/PACF et le test de Ljung–Box aux retards 24 et 168 vérifient si les innovations à un pas restent autocorrélées. Ce diagnostic utilise le plus long bloc continu d'apprentissage après amorçage, sans recoller les périodes séparées par des valeurs manquantes.

Nous calculons les critères d'information :

$$\mathrm{AIC} = -2\widehat{\ell} + 2k, \qquad \mathrm{BIC} = -2\widehat{\ell} + k\log(n).$$

$\widehat{\ell}$ est la log-vraisemblance au maximum estimé, k le nombre de paramètres et n le nombre d'observations disponibles dans l'apprentissage. La formule de l'AIC est celle des slides de modélisation (diapositive 33) ; le BIC, mentionné dans le cours, utilise sa définition usuelle. La variance des innovations est un paramètre : $k = 2$ pour AR(1) et MA(1), $k = 3$ pour AR(2) et ARMA(1,1), sans constante.

Le script `criteres_information.py` reprend les coefficients enregistrés et recalcule la vraisemblance sans réestimation, à la même échelle en GW. Pour le BIC, n exclut les valeurs masquées, d'où un léger écart avec la valeur automatique du logiciel qui compte la longueur de la grille. Un critère plus faible est préféré entre modèles ajustés sur les mêmes dates, la même transformation et la même échelle. Ces critères complètent les erreurs de prévision, sans les remplacer.

2.3.3 Estimation et évaluation chronologique

L'exploration utilise 2012–2023 ; les évaluations internes portent sur 2021, 2022 et 2023. Pour chaque année, les ARMA sont réestimés sur les deux années précédant la première coupure, le 31

décembre à 8 h. Cette fenêtre de deux ans est un choix pratique fixé avant le calcul : elle limite le temps d'estimation et privilégie les observations récentes, pour tenir compte d'une possible évolution des comportements de consommation. Sa durée n'a pas été optimisée ni comparée à un apprentissage sur toute la période depuis 2012 ; nous ne supposons donc pas qu'elle soit optimale. À l'inverse, les régressions présentées ensuite utilisent toutes les années antérieures disponibles depuis 2012. Les deux familles ne reposent donc pas sur la même longueur d'historique d'apprentissage. Les paramètres restent constants dans l'année ; les états filtrés sont actualisés avec les nouvelles observations autorisées. Le candidat ARMA est retenu par RMSE agrégée interne, puis évalué sur 2024 sans nouveau choix d'hyperparamètres. L'année 2024 ayant déjà été consultée lors des explorations précédentes, elle reste une validation ; le test final 2025 n'est pas évalué.

Pour simuler la prévision à J, 14 h, la consommation est limitée à J, 8 h pour les sept méthodes. Cette marge conservatrice suppose que la moyenne incluant 8 h 30 est publiée avant 14 h, sans le garantir historiquement. Les prévisions sont récursives jusqu'à $J+1$, 23 h ; l'inversion utilise

$$\widehat{C}_t = \widehat{z}_t + \widehat{C}_{t-1} + \widehat{C}_{t-24} - \widehat{C}_{t-25},$$

avec observations pour les termes déjà connus et prévisions pour les autres. Aucune observation de l'horizon n'est réinjectée. L'inversion et le caractère causal du filtrage sont contrôlés numériquement. Les jours incomplets, les historiques de 25 heures incomplets et les références hebdomadaires manquantes sont exclus pour toutes les méthodes. Les trous ne sont pas recollés.

Pour N heures évaluées, nous posons $e_t = C_t - \widehat{C}_t$ et calculons

$$\mathrm{MAE} = \frac{1}{N}\sum_t |e_t|, \qquad \mathrm{RMSE} = \sqrt{\frac{1}{N}\sum_t e_t^2}, \qquad \mathrm{biais} = \frac{1}{N}\sum_t e_t.$$

La RMSE pénalise davantage les grandes erreurs. Un biais négatif indique une surestimation moyenne. L'erreur d'énergie quotidienne est $\sum_{h=0}^{23} e_{J,h} \times 1\,\mathrm{h}$, en MWh. Nous examinons aussi la différence entre les pointes prévues et observées, ainsi qu'entre leurs heures ; les résumés journaliers utilisent les valeurs absolues. Les résultats sont étudiés par année et par heure, puis sur trois journées de fortes erreurs. Les innovations à un pas et les erreurs de prévision de J+1 sont deux diagnostics distincts.

2.4 Modèles d'apprentissage supervisé (ML)

2.4.1 Régression linéaire multiple : modèle M09

La deuxième famille utilise des variables explicatives pour apprendre la consommation cible. La régression linéaire multiple M09 constitue le premier modèle étudié dans cette partie. Elle représente simultanément la tendance, les saisons, le calendrier et la météo. Elle porte directement sur la consom-

mation en MW, sans différenciation ni retrait préalable de la tendance :

$$C_t = \beta_0 + \sum_{j=1}^{215} \beta_j X_{t,j} + u_t.$$

Il s'agit de 215 colonnes explicatives construites à partir de quelques variables sources, et non de 215 mesures indépendantes. La constante porte le total à 216 coefficients. Le tableau 2 détaille cette construction, identique à celle du script `decomposition_meteo_calendrier.py`.

TABLEAU 2 – Construction des 215 colonnes de M09, hors constante.

Groupe	Nombre	Codage
Tendance	1	Temps écoulé depuis le 1er janvier 2012, en années de 365,2425 jours.
Cycle annuel	6	Trois paires sinus/cosinus de fréquences 1, 2 et 3 par an.
Heure	23	Indicatrices des heures 1 à 23 ; 0 h en référence.
Jour × heure	144	Six jours, du mardi au dimanche, croisés avec 24 heures ; lundi en référence.
Jours fériés	24	Une indicatrice et 23 interactions avec l'heure ; effet spécifique à chaque heure.
Vacances	3	Indicatrices des zones A, B et C ; leurs contributions s'additionnent en cas de chevauchement.
Température	7	T et six fonctions $(T-k)_+$, pour $k = 0, 5, 10, 15, 20, 25$ °C.
Température × horaire	6	Termes froid et chaud dans les plages 6–11, 12–17 et 18–23 h ; 0–5 h en référence.
Précipitations	1	$\log(1+P)$, avec P en mm/h.
Total	215	Une constante supplémentaire est estimée.

La notation $(x)_+ = \max(x, 0)$ définit les changements de pente de la température : sa contribution est continue et linéaire par morceaux. Les interactions horaires utilisent $(18 - T)_+$ et $(T - 22)_+$ pour autoriser une sensibilité au froid et au chaud différente selon le moment de la journée. Les seuils sont fixés dans le code, non optimisés sur 2024. La transformation logarithmique de la pluie atténue l'influence des fortes valeurs. Le modèle reste linéaire en ses coefficients, malgré la non-linéarité des variables transformées.

Tous les effets sont ajustés ensemble par moindres carrés ordinaires, avec constante et sans pénalisation :

$$(\widehat{\beta}_0, \widehat{\beta}) = \arg\min_{b_0, b} \sum_{t \in \mathcal{T}} \left(C_t - b_0 - \sum_{j=1}^{215} b_j X_{t,j} \right)^2 .$$

Le rang de la matrice centrée est contrôlé à chaque ajustement. Les catégories de référence évitent les redondances avec la constante. Le modèle estime des associations conditionnelles : les effets de météo, saison et calendrier sont corrélés et ne s'interprètent pas comme des effets causaux. Aucun intervalle de confiance fondé sur l'indépendance des erreurs n'est présenté.

2.4.2 Variantes, ablations et décomposition descriptive

Dix-huit variantes sont comparées : ajout progressif du jour de semaine, des jours fériés, des vacances, de la température linéaire puis par seuils ou morceaux, de la pluie et des interactions ; une

tendance par morceaux est également testée. Les ablations retirent séparément pluie, vacances, jours fériés et température de M09. Toutes les variantes utilisent les mêmes heures où consommation et météo sont disponibles, hors changements d'heure, même lorsqu'une variante n'emploie pas la météo.

L'évaluation interne prévoit successivement les valeurs de 2021, 2022 et 2023 après ajustement sur toutes les années antérieures depuis 2012. Le classement repose sur la RMSE des erreurs horaires regroupées, et non sur la moyenne des RMSE annuelles. La météo de l'heure cible est observée : cette étape sélectionne une relation explicative à météo parfaite, pas une prévision opérationnelle. Pour les figures descriptives uniquement, le modèle retenu est ensuite réajusté sur 2012–2023 ; les contributions sont centrées et leur moyenne est reportée dans le niveau constant, sans modifier la somme ajustée.

2.4.3 Correction des résidus et prévision du lendemain

Le résidu u_t est la différence entre la consommation observée et la valeur ajustée par M09. Sa dépendance temporelle est représentée par une correction autorégressive. Une seconde régression par moindres carrés estime :

$$u_t = a + \sum_{\ell \in L} \phi_\ell u_{t-\ell} + \varepsilon_t.$$

Deux ensembles de retards sont comparés : $L = \{1, 2, 3\}$ et $L = \{1, 2, 3, 24, 25, 48, 168\}$. Cette estimation en deux étapes n'est pas un ajustement conjoint par maximum de vraisemblance. La prévision finale additionne la régression $\widehat{f}(X_t)$ et la correction $\widehat{u}_t$. Après la coupure, les résidus futurs sont prévus récursivement, sans réinjecter de consommation observée dans l'horizon.

L'essai interne J+1 ajuste annuellement les deux régressions jusqu'au 30 décembre précédant l'année évaluée. À chaque origine J, 14 h, il utilise la consommation jusqu'à 12 h et un historique commun complet de 168 heures. M09 seul, les deux corrections AR et les trois benchmarks sont comparés sur les mêmes journées. La météo parfaite, y compris celle utilisée pour reconstruire certains résidus récents, rend cet essai non opérationnel.

En validation 2024, les coefficients sont figés après ajustement jusqu'au 30 décembre 2023. Trois versions avec correction AR saisonnière sont évaluées : M09 à météo parfaite ; M09 alimenté par les températures et pluies aux mêmes heures UTC 48 h auparavant ; et une régression réestimée sans aucun terme météo (201 colonnes, plus constante). La coupure commune est J, 8 h. Pour les scénarios utilisant le passé, la disponibilité des mesures sources est contrôlée avec un délai de publication SYNOP supposé de trois heures. Les cibles, l'historique et les quatre références hebdomadaires doivent être complets pour toutes les méthodes. MAE, RMSE et biais sont calculés sur les mêmes heures ; énergie et pointe complètent l'essai interne. Les erreurs J+1 sont distinguées des innovations conditionnelles à une heure.

Les trois protocoles ont des supports et des coupures distincts : aucun gain n'est calculé entre leurs tableaux. Le test final 2025 reste non évalué. Les délais historiques réels, les révisions RTE et la sélection des stations sur une période dépassant l'apprentissage limitent l'interprétation opérationnelle.

3 Résultats

3.1 Données préparées et analyse descriptive

La base de consommation couvre 2012–2025. Sur l'apprentissage 2012–2023, la grille comprend 105 192 étiquettes horaires, sans doublon ni consommation manquante. Cette régularité des étiquettes ne résout pas les ambiguïtés physiques des changements d'heure, exclus des modèles météo et de prévision selon le protocole décrit dans la méthode.

Après exclusion des 576 heures correspondant aux 24 journées de changement d'heure du train et de 139 autres heures sans météo complète, 104 477 heures sont utilisables pour la régression descriptive.

La sélection météorologique retient 37 stations présentant chacune plus de 95 % de données de température et de précipitations. Environ 45,1 % de la surface métropolitaine se situe à moins de 50 km d'une station et 97,3 % à moins de 100 km ; la distance médiane surfacique est de 53,0 km (figure 1). Les proportions à 50 et 100 km varient de moins de 0,01 point de pourcentage entre les deux maillages les plus fins. Ces estimations dépendent du contour simplifié et des positions de référence : la proximité géographique ne garantit ni la représentativité climatique ni une pondération adaptée à la population.

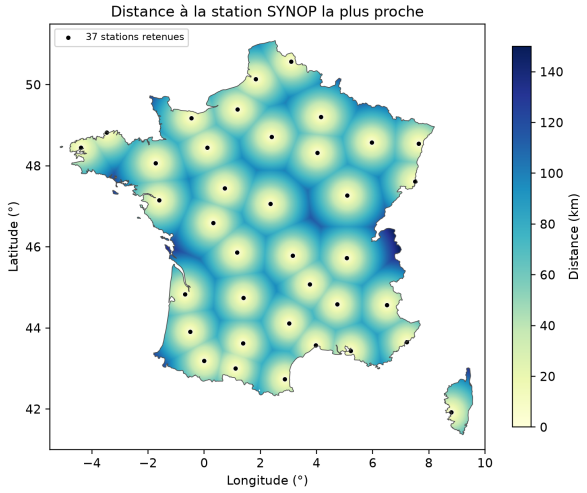


FIGURE 1 – Répartition des 37 stations SYNOP et distance à la station la plus proche. Le seuil de sélection de 95 % concerne la disponibilité temporelle de chaque variable, et non la surface couverte. Fond : Natural Earth ; stations : Météo-France.

Les profils de la figure 2 montrent une consommation plus faible la nuit et le week-end, et plus élevée en hiver. La moyenne mobile annuelle passe de 55 389 à 49 723 MW entre juillet 2012 et juillet 2023, les premiers et derniers points estimables, soit une baisse de 10,2 %. Cette évolution n'est ni régulière ni corrigée du climat ; retirer cette tendance laisse subsister les fluctuations saisonnières (figure 3).

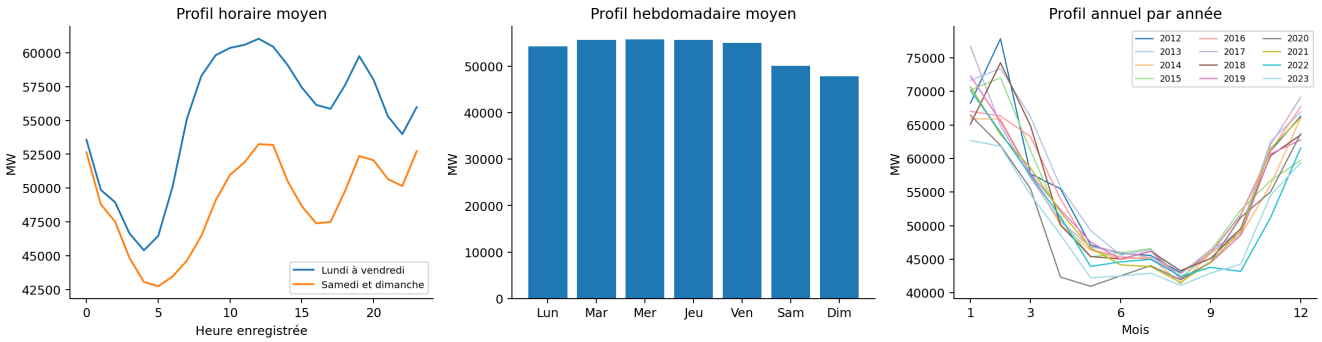


FIGURE 2 – Visualisation de la consommation d'apprentissage : profils horaires selon le type de jour, moyennes par jour de semaine et profils mensuels par année. Les effets météo et calendaires ne sont pas corrigés.

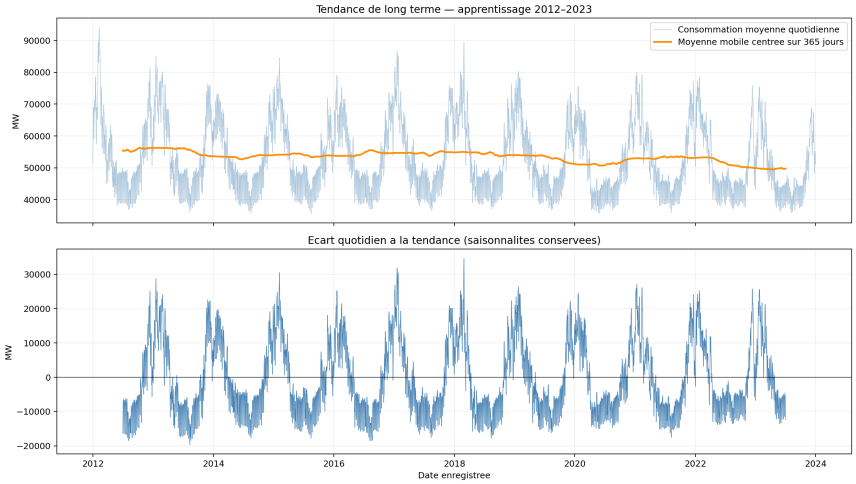


FIGURE 3 – Consommation moyenne quotidienne et moyenne mobile centrée sur 365 jours (haut), puis écarts à cette tendance (bas). Les 182 jours de chaque bord restent sans estimation. La saisonnalité est conservée dans les écarts.

3.2 Comparaison des décompositions

Les décompositions additives moyennes donnent les plus faibles RMSE descriptives aux échelles journalière et hebdomadaire (2 130 et 2 360 MW) ; le multiplicatif moyen est meilleur sur les moyennes mensuelles (2 067 MW). Ces erreurs d'ajustement ne sont ni des scores prédictifs ni comparables entre échelles. La différence à 364 jours fonctionne mieux à heure identique qu'avec un décalage de ± 1 h.

STL standard réduit davantage l'erreur d'ajustement : sa RMSE vaut 1 209 MW à l'échelle journalière et 1 505 MW à l'échelle hebdomadaire, contre 2 999 et 2 893 MW pour STL robuste. Cela ne suffit pas à choisir un modèle prédictif : le lissage utilise les observations des deux côtés de chaque date. La variante robuste peut moins bien ajuster les valeurs inhabituelles puisqu'elle réduit leur poids.

Aucune transformation ne produit clairement un bruit blanc. Parmi les 36 variantes horaires, STL hebdomadaire robuste suivi d'une différence à 1 h minimise l'ACF quadratique moyenne, mais conserve

une ACF de 0,638 à 168 h. Les différences successives à 364 jours, 24 h et 1 h conservent une ACF de 0,657 à 1 h. Le choix prédictif doit donc reposer sur une validation temporelle.

3.3 Modèles du cours : AR, MA et ARMA

Les quatre modèles AR, MA et ARMA et les trois benchmarks sont évalués sur 1 053 journées internes (25 272 heures) et 352 journées en validation 2024 (8 448 heures). Les seize ajustements convergent. AR(2) minimise les critères AIC et BIC dans chaque fenêtre annuelle et donne la meilleure RMSE interne parmi les quatre ARMA. AR(2) est retenu dans cette famille sur la base de la RMSE interne. Sur ces mêmes dates, sa RMSE est de 8 022 MW, contre 5 388 MW pour la semaine précédente, 5 979 MW pour la moyenne des quatre semaines et 7 585 MW pour la persistance.

Le tableau 3 présente les critères recalculés avec les formules de la méthode. Les valeurs minimales sont en gras au sein de chaque fenêtre. AR(2) est préféré par les deux critères dans les quatre ajustements annuels. Par exemple, pour prévoir 2024, il donne $\widehat{\ell} = -12\,800{,}75$, $k = 3$ et $n = 17\,324$, soit AIC $= 25\,607{,}5$ et BIC $= 25\,630{,}8$. Ces critères portent sur l'apprentissage avant 2024, pas sur les observations de validation. Leur classement ne garantit pas une meilleure prévision que les benchmarks.

TABLEAU 3 – Critères d'information sur la même série doublement différenciée, exprimée en GW. Chaque année désigne l'année prévue ; les critères utilisent la fenêtre d'apprentissage antérieure de deux ans. Comparaison uniquement à l'intérieur d'une année.

Année prévue	Modèle	k	AIC	BIC
2021	AR(1)	2	30931,6	30947,1
2021	AR(2)	3	**27615,3**	**27638,6**
2021	MA(1)	2	30863,6	30879,1
2021	ARMA(1,1)	3	28076,6	28099,9
2022	AR(1)	2	29401,2	29416,7
2022	AR(2)	3	**26104,6**	**26127,9**
2022	MA(1)	2	29570,6	29586,1
2022	ARMA(1,1)	3	26689,9	26713,2
2023	AR(1)	2	29728,3	29743,8
2023	AR(2)	3	**26777,0**	**26800,3**
2023	MA(1)	2	30144,2	30159,7
2023	ARMA(1,1)	3	27386,7	27410,0
2024	AR(1)	2	28474,1	28489,6
2024	AR(2)	3	**25607,5**	**25630,8**
2024	MA(1)	2	28724,4	28739,9
2024	ARMA(1,1)	3	26126,2	26149,5

En 2024, le benchmark de la semaine précédente atteint une RMSE de 4 860 MW, contre 8 210 MW pour AR(2). La moyenne de quatre semaines atteint 5 362 MW. Les RMSE des quatre modèles AR, MA et ARMA sont comprises entre 8 210 et 11 861 MW, toutes supérieures à celle de la semaine précédente sur ce support.

Les innovations d'AR(2) restent structurées (figure 4). Sur le bloc analysé pour l'ajustement précé-

TABLEAU 4 – Erreurs en MW, sur des dates communes à l'intérieur de chaque période. Coupure à J, 8 h pour une prévision produite à 14 h. Le tableau est généré depuis les sorties du script.

Modele	RMSE 2021–2023	MAE 2024	RMSE 2024
Persistance consommation	7585	5716	7119
Semaine précédente	5388	3226	4860
Moyenne des 4 semaines	5979	3690	5362
AR1	11619	8519	11861
AR2	8022	6152	8210
MA1	8969	6606	8839
ARMA11	9540	7194	9784

dant 2024, le test de Ljung–Box rejette l'absence d'autocorrélation aux retards 24 et 168 ($p < 0{,}001$). Les ACF/PACF présentent encore des pics aux retards saisonniers. Ce diagnostic porte sur les innovations à un pas ; le tableau 4 porte sur les erreurs des 24 heures du lendemain.

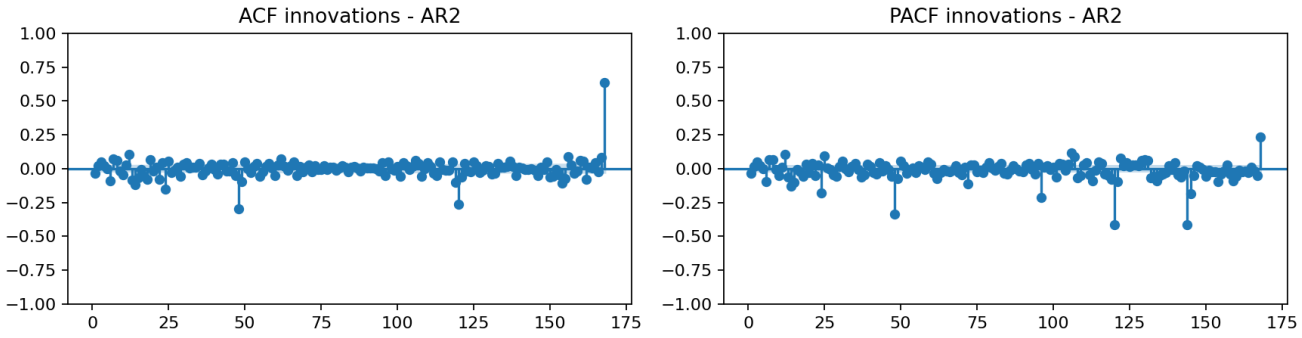


FIGURE 4 – Innovations à un pas d'AR(2) sur la série différenciée, pour l'ajustement précédant 2024. Le diagnostic utilise un bloc continu de 5 159 heures en 2022 ; ce ne sont pas les erreurs de prévision J+1.

3.4 Modèles d'apprentissage supervisé (ML)

3.4.1 Régression M09 : variables et ablations

Sur 26 076 heures communes de 2021–2023, M09 obtient la plus faible RMSE parmi les 18 variantes : 2 955 MW, pour une MAE de 2 269 MW et un biais de -767 MW. Avec la convention observation moins prévision, ce biais indique une surestimation moyenne. Le tableau 5 distingue l'enrichissement progressif et les ablations du modèle retenu. La RMSE passe de 4 180 MW avec température linéaire à 3 274 MW avec les seuils chaud/froid. Retirer la pluie ou les vacances de M09 augmente légèrement la RMSE, mais diminue légèrement la MAE. La variante à tendance plus flexible obtient une RMSE de 3 304 MW.

La relation ajustée à la température dépend de l'heure (figure 5). Dans le réajustement descriptif sur 2012–2023, la pente de base entre 5 et 10 °C vaut environ $-1\,457$ MW par degré entre 0 et 5 h ; elle atteint $-1\,820$ MW par degré entre 12 et 17 h avec l'interaction froid. Ce sont des associations à contexte

TABLEAU 5 – Régressions avec météo observée, sur les mêmes 26 076 heures internes. Chaque ablation réestime les coefficients après retrait du groupe.

Méthode	MAE (MW)	RMSE (MW)
Calendrier sans météo (M03)	3641	4882
Température linéaire (M04)	3252	4180
Température par seuils (M05)	2545	3274
Température par morceaux et pluie (M08)	2369	3053
M09 : interactions horaires	2269	2955
M09 sans température	3610	4857
M09 sans jours fériés	2349	3075
M09 sans vacances	2257	2993
M09 sans pluie	2267	2962

fixé, et non des effets causaux ni des performances de prévision. De même, les coefficients associés aux vacances A, B et C valent respectivement environ -342, -675 et -594 MW ; leur interprétation dépend du chevauchement des calendriers et des autres variables.

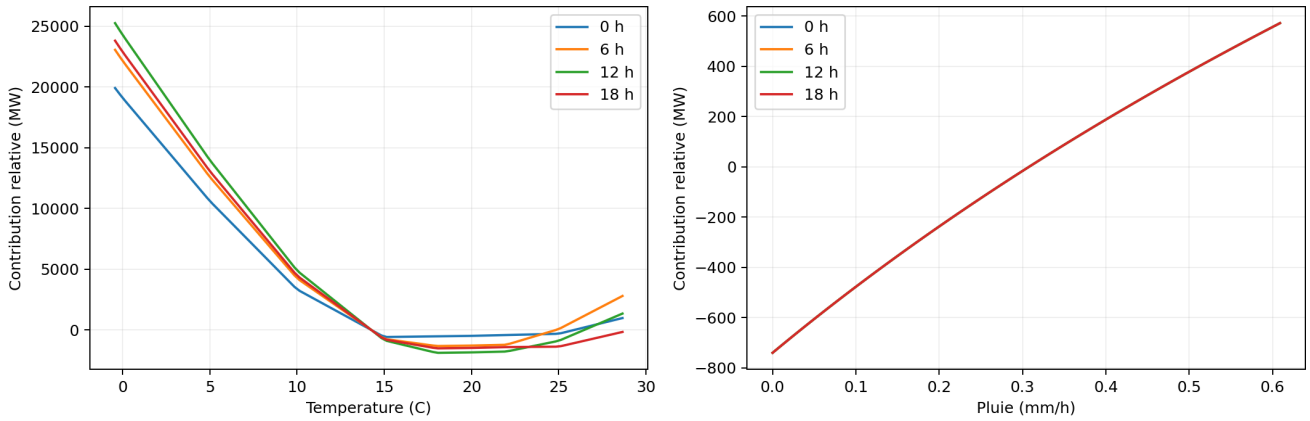


FIGURE 5 – Contributions météo relatives de M09 réajusté sur 2012–2023, à contexte fixé. Les courbes sont recentrées pour comparer leur forme. La pluie a un coefficient positif conditionnel, mais son ablation montre un faible gain prédictif.

3.4.2 Résidus et correction autorégressive

Les erreurs internes de M09 restent fortement autocorrélées : ACF de 0,946 à 1 h, 0,804 à 24 h et 0,504 à 168 h. Sur les 991 journées communes de l'essai J+1 à météo parfaite, la correction AR courte ramène la RMSE de 2 877 à 2 562 MW ; les retards journaliers et hebdomadaires la ramènent à 1 751 MW, soit un gain de 39,1 % par rapport à M09 seul (tableau 6). Le gain est observé dans chacune des trois années.

Avec la correction saisonnière, l'erreur absolue moyenne d'énergie quotidienne passe de 46 893 à 23 665 MWh, celle de la valeur de pointe de 1 975 à 1 048 MW et celle de son heure de 2,46 à 1,63 h. Les innovations à un pas restent toutefois corrélées, notamment à 168 h (ACF de 0,220). Ces scores ne sont pas ceux du tableau 5 : les exclusions et la date de fin d'estimation diffèrent.

TABLEAU 6 – Prévision J+1 sur 991 jours communs de 2021–2023. Consommation disponible à J, 12 h, et météo parfaite pour les régressions.

Méthode	MAE (MW)	RMSE (MW)
Persistance consommation	6687	8048
Semaine précédente	3520	5336
Moyenne des quatre semaines	4249	5968
M09 seul	2193	2877
M09 + AR court	1938	2562
M09 + AR journalier/hebdomadaire	1200	1751

3.4.3 Validation 2024 selon le scénario météo

Sur 333 journées communes (7 992 heures), la régression sans météo avec correction AR obtient une RMSE de 2 546 MW, contre 4 932 MW pour la semaine précédente, soit un gain de 48,4 %. Répéter la météo de 48 h auparavant dégrade la RMSE à 3 350 MW. Avec la météo réellement observée du lendemain, M09 atteint 2 020 MW : ce scénario utilise les observations futures et constitue une comparaison à météo parfaite.

TABLEAU 7 – Validation 2024 sur les mêmes 333 journées, coupure à J, 8 h. Les régressions incluent la correction AR saisonnière. Biais : observation moins prévision.

Méthode	MAE (MW)	RMSE (MW)	Biais (MW)
Persistance consommation	5661	7055	-671
Semaine précédente	3251	4932	246
Moyenne des quatre semaines	3584	5296	505
Régression sans météo + AR	1784	2546	14
M09, météo répétée à 48 h + AR	2307	3350	7
M09, météo parfaite + AR	1444	2020	-99

Le scénario météo répétée présente un biais global de 7 MW, avec des erreurs quotidiennes de signes opposés. Les 22 janvier et 25 novembre 2024, la température observée dépasse la référence de 48 h de 8,9 et 7,2 °C en moyenne ; la consommation est fortement surestimée. Le 20 janvier, l'écart est de $-6,7$ °C et la consommation est sous-estimée. La figure 6 montre ces écarts. Les RMSE quotidiennes sont respectivement de 14 868, 14 380 et 10 991 MW. Les écarts de température et les erreurs de consommation sont relevés sur les mêmes journées ; cette comparaison descriptive n'isole pas une relation causale.

Ces résultats correspondent à 333 journées communes, contre 352 pour la comparaison AR, MA et ARMA précédente. Les modèles ne sont donc pas classés ensemble à partir de ces tableaux : les dates et les historiques requis diffèrent. Le test final 2025 n'a pas été évalué.

4 Discussion

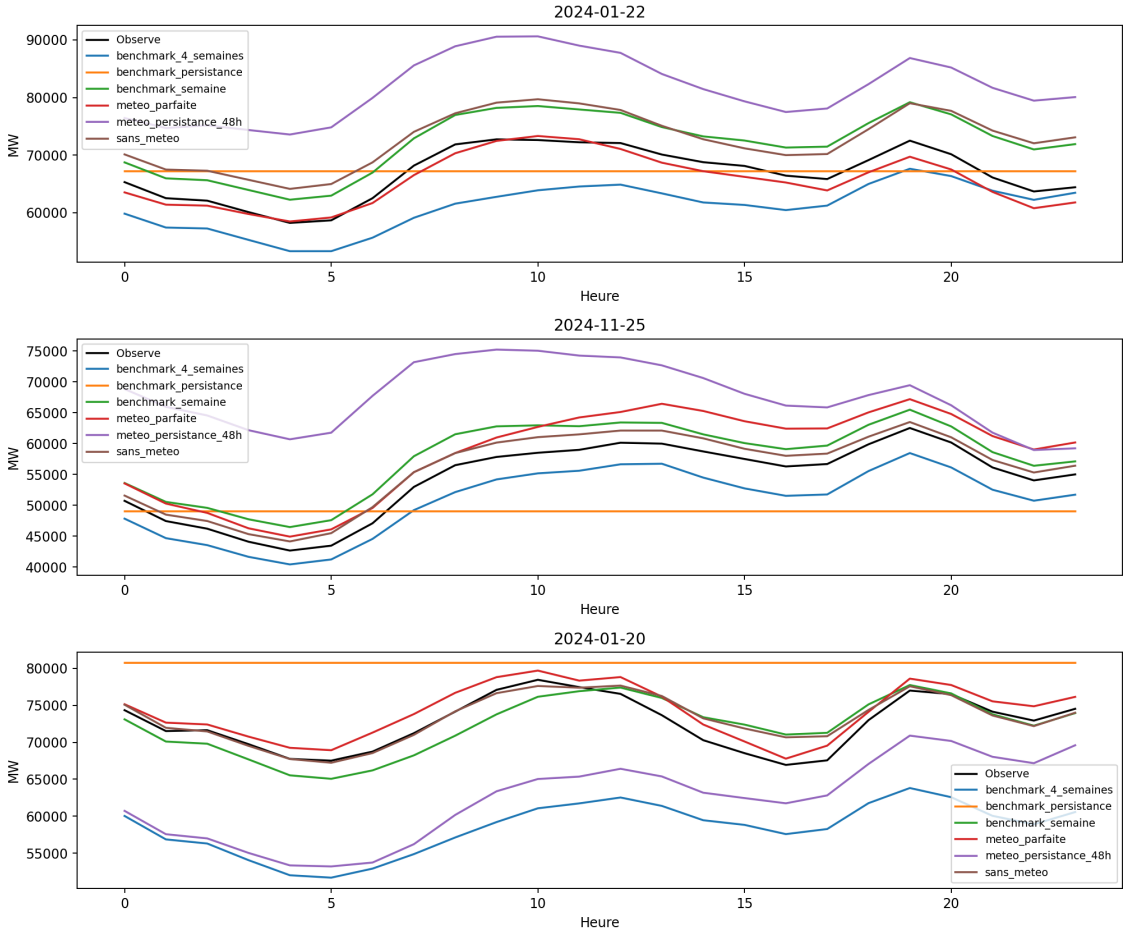


FIGURE 6 – Trois plus fortes erreurs du scénario à météo répétée à 48 h. La consommation est surestimée les 22 janvier et 25 novembre, et sous-estimée le 20 janvier. Les prévisions sont comparées aux observations sur les mêmes 24 heures locales.

4.1 Disponibilité des données et risques de fuite

4.2 Analyse de trois journées d'échec

4.3 Robustesse et limites des modèles

4.4 Trois exemples documentés d'usage des agents IA

Références

Augusti, A. (2026). *Vacances scolaires par zones* [Jeu de données, dernière mise à jour le 29 octobre 2026]. data.gouv.fr. Récupérée novembre 5, 2026, à partir de https://www.data.gouv.fr/datasets/vacances-scolaires-par-zones/informations

Gouvernement français. (2026). *Jours fériés en France métropolitaine* [Jeu de données, dernière mise à jour le 2 octobre 2026]. data.gouv.fr. Récupérée novembre 5, 2026, à partir de https://www.data.gouv.fr/datasets/jours-feries-en-france-metropolitaine

Météo-France. (2026). Données SYNOP essentielles OMM [Consulté le 04-11-2026].

RTE. (2026). éCO2mix : Les données de l'électricité en temps réel [Consulté le 04-11-2026].